Valutazione Comparativa di una Pipeline Retrieval-Augmented Generation

Contents

1 Dataset **3**
- 1.1 Estrazione dei documenti . . . 3

2 Pipeline **3**
- 2.1 Estrazione . . . 4
- 2.2 Chunking . . . 4
  - 2.2.1 Fixed Chunking . . . 4
  - 2.2.2 Sliding Window Chunking . . . 5
  - 2.2.3 Hybrid Chunking . . . 6
- 2.3 Retriever . . . 6
  - 2.3.1 Dense Retriever . . . 6
  - 2.3.2 Sparse Retriever . . . 7
  - 2.3.3 Retriever Ibridi . . . 7
  - 2.3.4 Reciprocal Rank Fusion . . . 7
- 2.4 Decomposizione delle Query . . . 8
  - 2.4.1 Modalità rerank_each . . . 8
  - 2.4.2 Modalità rerank_once . . . 8
- 2.5 Reranking . . . 9

3 Dataset e Query di Valutazione **9**

4 Metodologia di Valutazione **10**
- 4.1 Precision@k . . . 11
- 4.2 Recall@k . . . 11
- 4.3 Average Precision (AP) . . . 12
- 4.4 Mean Average Precision (MAP) . . . 12
- 4.5 Discounted Cumulative Gain (DCG) . . . 13
- 4.6 Normalized Discounted Cumulative Gain (nDCG) . . . 13
- 4.7 Valutazione Granulare e MAP per Domanda Madre . . . 13
- 4.8 Valutazione delle Pipeline Multi-Query . . . 14
- 4.9 Baseline Random . . . 14
- 4.10 Valori Attesi della Baseline Random . . . 15
- 4.11 Generazione della Risposta . . . 15

5 Confronto tra gli Esperimenti **15**
- 5.1 Esperimenti A1 vs A2 . . . 15
- 5.2 Esperimenti B1 vs B2 . . . 16

6 Interpretazione dei Grafici **16**
6.1 Grafici di Ranking . . . 16
6.2 Grafici Chunking vs Retriever . . . 16
6.3 Grafici B1 vs B2 . . . 16
6.4 Grafici delle Metriche al variare di k . . . 17

7 Risultati **17**
7.1 COMPAS . . . 17
7.1.1 Effetto della strategia di chunking . . . 18
7.1.2 Caratteristiche dei chunk . . . 18
7.1.3 Confronto con la baseline casuale . . . 19
7.1.4 Analisi delle query . . . 19
7.1.5 Conclusioni COMPAS . . . 20
7.2 D_German . . . 21
7.2.1 Effetto della strategia di chunking . . . 21
7.2.2 Caratteristiche dei chunk . . . 22
7.2.3 Confronto con la baseline casuale . . . 23
7.2.4 Analisi delle query . . . 24
7.2.5 Conclusioni D_German . . . 25
7.3 B_Adult . . . 26
7.3.1 Effetto della strategia di chunking . . . 27
7.3.2 Caratteristiche dei chunk . . . 28
7.3.3 Confronto con la baseline casuale . . . 29
7.3.4 Analisi delle query . . . 30
7.3.5 Conclusioni B_Adult . . . 31
7.4 EHSRQL . . . 32
7.4.1 Effetto della strategia di chunking . . . 33
7.4.2 Caratteristiche dei chunk . . . 35
7.4.3 Confronto con la baseline casuale . . . 36
7.4.4 Analisi delle query . . . 37
7.4.5 Conclusioni EHSRQL . . . 39
7.5 Analisi degli Errori . . . 40

8 Conclusioni **40**

1 Dataset

Il dataset utilizzato consiste in una collezione di documenti PDF appartenenti al dominio oggetto di studio. Per ogni documento è stato costruito un insieme di domande di valutazione e il relativo ground truth, utilizzato per misurare la qualità del recupero dell'informazione.

La pipeline utilizza due differenti rappresentazioni del ground truth:

- **Ground Truth Aggregato**: ad ogni domanda è associato l'insieme completo dei chunk rilevanti.
- **Ground Truth Granulare**: ogni domanda viene decomposta in sotto-domande, ciascuna associata ai propri chunk rilevanti.

Questa distinzione permette di valutare separatamente:

1. l'effetto del retriever;
2. l'effetto della decomposizione delle query;
3. l'effetto delle strategie di chunking.

1.1 Estrazione dei documenti

I PDF vengono elaborati tramite una fase di parsing che estrae:

- testo digitale;
- tabelle;
- metadati relativi alla provenienza dei contenuti.

Le tabelle vengono convertite in formato Markdown e successivamente fuse con il testo estratto, ottenendo una rappresentazione unica del documento.

Il risultato finale viene salvato in formato JSON e costituisce l'input delle successive fasi di chunking.

2 Pipeline

La pipeline implementa un sistema completo di Retrieval-Augmented Generation (RAG), organizzato nelle seguenti fasi:

1. Estrazione del contenuto dai PDF;
2. Generazione dei chunk;
3. Indicizzazione tramite retriever sparsi e densi;
4. Recupero dei candidati;
5. Eventuale decomposizione della query;
6. Reranking dei documenti recuperati;
7. Generazione della risposta finale.

La Figura 1 riassume il flusso generale.



Figure 1: Pipeline generale del sistema.

2.1 Estrazione

La fase di estrazione è responsabile della conversione dei documenti PDF in una rappresentazione strutturata.

L'estrazione comprende:

- recupero del testo tramite PyMuPDF;
- estrazione delle tabelle tramite pdfplumber;
- conversione delle tabelle in Markdown;
- fusione di tutte le informazioni in un unico oggetto JSON.

2.2 Chunking

Lo scopo del chunking è suddividere i documenti in unità informative utilizzabili dal retriever.

La qualità del retrieval dipende fortemente dalla strategia utilizzata per segmentare i documenti. Un chunk troppo piccolo può perdere contesto semantico, mentre un chunk troppo grande può introdurre rumore e ridurre la precisione del recupero. Nel sistema sono state implementate e confrontate tre differenti strategie di chunking:

- Fixed Chunking;
- Sliding Window Chunking;
- Hybrid Chunking.

Ogni chunk memorizza inoltre i seguenti metadati:

- identificatore univoco (`chunk_id`);
- pagine sorgenti;
- strategia di chunking utilizzata;
- presenza o assenza di tabelle;
- pdf di provenienza.

Fixed Chunking

2.2.1 Fixed Chunking

La strategia Fixed utilizza una suddivisione basata sul numero di caratteri.

I parametri utilizzati sono:

$$chunk_size = 512$$

$$overlap = 64$$

Il testo viene segmentato utilizzando una finestra mobile con passo:

$$step = chunk_size - overlap$$

ovvero:

$$step = 448$$

caratteri.

Ogni blocco testuale viene diviso in segmenti consecutivi:

$$C_i = text[i : i + chunk_size]$$

introducendo una sovrapposizione di 64 caratteri tra chunk consecutivi.

Le tabelle vengono gestite separatamente e salvate come chunk autonomi.

Questa soluzione garantisce semplicità implementativa e uniformità dimensionale, ma può interrompere frasi o strutture semantiche rilevanti.

Il documento viene suddiviso in segmenti di lunghezza fissa con overlap controllato.

Vantaggi:

- semplicità implementativa;
- dimensioni prevedibili dei chunk.

Svantaggi:

- possibile interruzione di frasi;
- possibile frammentazione delle tabelle.

2.2.2 Sliding Window Chunking

La strategia Sliding Window opera a livello sintattico utilizzando la segmentazione in frasi fornita da spaCy.

I parametri utilizzati sono:

$$sentences_per_chunk = 6$$

$$overlap_sentences = 2$$

Ogni chunk contiene pertanto sei frasi consecutive.

Il passo della finestra vale:

$$step = 6 - 2 = 4$$

frasi.

Indicando con

$$S_1, S_2, \ldots, S_n$$

la sequenza delle frasi del documento, il chunk generico risulta:

$$C_i = \{S_i, S_{i+1}, ..., S_{i+5}\}$$

mentre il chunk successivo inizia dalla quarta frase successiva.

Questa strategia preserva maggiormente la struttura logica del testo e riduce il rischio di interrompere concetti distribuiti su più frasi.

Vantaggi:

- migliore conservazione del contesto;
- minore perdita di informazioni ai bordi.

Svantaggi:

- aumento della ridondanza;
- maggiore numero complessivo di chunk.

2.2.3 Hybrid Chunking

La strategia Hybrid combina segmentazione a caratteri e gestione strutturata delle tabelle.

Per il testo vengono utilizzati gli stessi parametri della strategia Fixed:

$$chunk_size = 512$$

$$overlap = 64$$

Per le tabelle viene invece costruito un chunk autonomo che include anche una porzione del contesto precedente:

$$table_context_chars = 200$$

caratteri.

Il chunk associato ad una tabella assume quindi la forma:

$$Chunk_{table} = Context_{200} + Table$$

dove $Context_{200}$ rappresenta gli ultimi 200 caratteri precedenti alla tabella.

2.3 Retriever

La fase di retrieval è responsabile dell'identificazione dei chunk potenzialmente rilevanti.

Sono state valutate tre categorie di retriever:

1. Dense Retriever;
2. Sparse Retriever;
3. Hybrid Retriever.

2.3.1 Dense Retriever

I retriever densi rappresentano query e documenti tramite embedding vettoriali.

Le rappresentazioni vengono indicizzate mediante FAISS.

Sono stati valutati i seguenti modelli:

- `single_bge` (BAAI/bge-small-en-v1.5);
- `single_e5` (intfloat/e5-small-v2);
- `single_bgem3` (TaylorAI/bge-micro-v2).

Per ogni query vengono recuperati inizialmente:

$$k = 20$$

candidati.

2.3.2 Sparse Retriever

Come baseline lessicale è stato utilizzato BM25.

La similarità è calcolata direttamente sul contenuto testuale dei chunk senza l'utilizzo di embedding neurali.

La configurazione corrispondente negli esperimenti è:

`single_bm25`

2.3.3 Retriever Ibridi

Per combinare più sistemi di retrieval vengono utilizzate configurazioni ensemble.

Le configurazioni considerate sono:

- `dense_bge_e5`
- `dense_bgem3_e5`
- `bm25_bge`
- `bm25_e5`

In tutti i casi ciascun retriever recupera inizialmente:

40

candidati.

Le classifiche vengono successivamente fuse tramite Reciprocal Rank Fusion.

2.3.4 Reciprocal Rank Fusion

Le configurazioni multi-retriever adottano la strategia Reciprocal Rank Fusion (RRF).

Nel sistema è utilizzata la costante:

$$RRF_k = 40$$

Il punteggio assegnato al documento d è:

$$RRF(d) = \sum_{i=1}^{N} \frac{1}{40 + rank_i(d)}$$

dove:

- N è il numero di retriever;
- $rank_i(d)$ è la posizione del documento nel ranking prodotto dal retriever i.

Documenti ben posizionati in più classifiche ricevono un punteggio maggiore e vengono promossi nelle prime posizioni del ranking finale. La fase di retrieval recupera un insieme iniziale di chunk candidati.

2.4 Decomposizione delle Query

Per le domande complesse il sistema può attivare una fase di decomposizione automatica.
Indicando con

$$Q$$

la domanda originale, il sistema genera un insieme di sotto-domande:

$$Q = \{q_1, q_2, \ldots, q_m\}$$

successivamente utilizzate nella fase di retrieval.

2.4.1 Modalità rerank_each

Per ogni sotto-domanda vengono eseguite le seguenti operazioni:

1. retrieval;
2. reranking tramite Cross Encoder;
3. fusione finale mediante RRF.

Per ciascuna sotto-domanda vengono recuperati:

$$k_{subquery} = 20$$

documenti candidati.
La lista finale è limitata a:

$$k_{final} = 20$$

documenti.

2.4.2 Modalità rerank_once

In questa configurazione il retrieval viene eseguito separatamente per ciascuna sotto-domanda, ma il reranking viene effettuato una sola volta.
Per ogni sotto-domanda vengono recuperati:

$$k_{subquery} = 30$$

candidati.
Le liste vengono:

1. unite;
2. deduplicate;
3. riordinate tramite Cross Encoder;
4. troncate ai migliori 20 risultati.

Formalmente:

$$D = \bigcup_{i=1}^{m} Retrieve(q_i)$$

$$Final = Rerank(D, Q)$$

2.5 Reranking

Dopo il retrieval, i chunk candidati vengono riordinati mediante un Cross Encoder.

Il modello utilizzato è:

`cross-encoder/ms-marco-MiniLM-L-6-v2`

Il reranker ricalcola direttamente la rilevanza query-documento, migliorando la qualità del ranking finale.

3 Dataset e Query di Valutazione

La valutazione sperimentale è stata condotta utilizzando tre dataset documentali differenti, denominati `B_Adult`, `C_COMPAS`, `D_German` ed `EHSRQL`. Per ciascun dataset è stata costruita una collezione di domande e relativi ground truth contenenti i chunk considerati rilevanti per la risposta. I ground truth sono memorizzati in formato JSONL e associano ad ogni domanda un identificatore univoco, una risposta di riferimento e l'insieme dei chunk rilevanti utilizzati durante la valutazione. [1-b77005][2-7ec5f3][3-e92ef6][4-03441c]

I tre dataset sono stati selezionati per rappresentare differenti tipologie di documentazione e consentire una valutazione della robustezza delle strategie di retrieval, chunking e decomposizione delle query in contesti differenti. Per tutti i dataset è stato utilizzato lo stesso protocollo sperimentale e la stessa metodologia di valutazione, in modo da garantire la confrontabilità dei risultati ottenuti. [2-7ec5f3][3-e92ef6][4-03441c]

Per ciascun dataset è stato definito un benchmark costituito da sei domande principali e ventiquattro sotto-domande. Le domande sono state progettate per coprire gli aspetti fondamentali della documentazione dei dati richiesti dall'Articolo 10 dell'AI Act, includendo informazioni sulla provenienza dei dati, sul processo di raccolta, sulle operazioni di preparazione, sulle caratteristiche rappresentate, sui possibili bias e sulle limitazioni del dataset. [1-b77005]

Le sei domande principali utilizzate durante gli esperimenti sono:

D1. *What is the purpose and origin of the data?*

- D1.1 Purpose for original data collection
- D1.2 People and organizations involved in data collection
- D1.3 Data collection mechanisms and procedures

D2. *What is the context in which the data was created?*

- D2.1 Timeframe of data collection
- D2.2 Geographical area of collection
- D2.3 Context of data collection

D3. *What data-preparation processing operations took place, including annotation, labelling, cleaning, updating, enrichment and aggregation?*

- D3.1 Sampling strategy
- D3.2 Data preprocessing
- D3.3 Data cleaning
- D3.4 Data labeling and annotation

D4. *What does the data (supposedly) measure and represent?*

- D4.1 Available features and covariates
- D4.2 Target variables
- D4.3 Dataset size
- D4.4 Assumptions about representativeness

D5. *Which data biases might lead to discrimination or otherwise impact fundamental rights?*

- D5.1 Protected attributes and discrimination risks
- D5.2 Marginal distributions of protected attributes
- D5.3 Joint distributions between protected attributes and targets
- D5.4 Expected distributions
- D5.5 Label provenance
- D5.6 Data-side bias mitigation strategies

D6. *What data gaps and shortcomings are there in the data?*

- D6.1 Sources of inaccuracy
- D6.2 Data gaps and under-representation
- D6.3 Severity of inaccuracies

Complessivamente il benchmark comprende 24 aspetti informativi distinti distribuiti su sei macro-categorie. Le domande principali vengono utilizzate nella valutazione aggregata del retrieval, mentre le sotto-domande vengono impiegate negli esperimenti di decomposizione delle query e nella valutazione granulare. Questa struttura consente di misurare sia la capacità del sistema di recuperare informazioni generali sia la sua efficacia nell'identificare specifici elementi informativi all'interno dei documenti. [1-b77005]

4 Metodologia di Valutazione

La valutazione del sistema di Information Retrieval (IR) è stata effettuata confrontando i chunk recuperati dal retriever con quelli presenti nel ground truth.

All'interno dell'intera pipeline, ogni documento viene identificato univocamente mediante la coppia:

$$(chunk_id, source)$$

dove:

- `chunk_id` identifica il chunk all'interno del documento;
- `source` identifica il dataset o il documento di provenienza.

L'utilizzo della coppia $(chunk_id, source)$ evita collisioni tra chunk appartenenti a documenti differenti ma aventi lo stesso identificatore locale.

Le metriche vengono calcolate sia nel caso del ground truth aggregato sia nel caso del ground truth granulare basato sulle sotto-domande.

Per ogni configurazione vengono valutati:

$$k \in \{5, 10, 20\}$$

e vengono quindi calcolate le metriche:

$$Precision@5, \quad Precision@10, \quad Precision@20$$

$$Recall@5, \quad Recall@10, \quad Recall@20$$

$$nDCG@5, \quad nDCG@10, \quad nDCG@20$$

oltre a:

- Average Precision (AP);
- Mean Average Precision (MAP).

4.1 Precision@k

La Precision@k misura la percentuale di documenti rilevanti presenti nei primi k risultati restituiti dal retriever.

Indicando con:

$$Retrieved_k$$

l'insieme dei primi k documenti recuperati e con

$$Relevant$$

l'insieme dei documenti rilevanti, si ha:

$$Precision@k = \frac{|Retrieved_k \cap Relevant|}{k}$$

Equivalentemente:

$$Precision@k = \frac{\sum_{i=1}^{k} rel(i)}{k}$$

dove

$$rel(i) = \begin{cases} 1 & \text{se il documento in posizione } i \text{ è rilevante} \\ 0 & \text{altrimenti} \end{cases}$$

Una precisione elevata indica che i primi risultati restituiti dal sistema sono effettivamente utili per la generazione della risposta.

4.2 Recall@k

La Recall@k misura la capacità del sistema di recuperare i documenti rilevanti disponibili.

Formalmente:

$$Recall@k = \frac{|Retrieved_k \cap Relevant|}{|Relevant|}$$

Oppure:

$$Recall@k = \frac{\sum_{i=1}^{k} rel(i)}{|Relevant|}$$

Un valore elevato di recall indica che la maggior parte dei chunk rilevanti è stata recuperata.

Nel contesto RAG questa proprietà è particolarmente importante poiché un documento non recuperato non può essere utilizzato dal modello generativo.

4.3 Average Precision (AP)

L'Average Precision rappresenta la metrica fondamentale utilizzata nel sistema.

Questa metrica tiene conto contemporaneamente:

1. della correttezza dei documenti recuperati;
2. della loro posizione all'interno del ranking.

Sia:

$$R = \{r_1, r_2, \ldots, r_n\}$$

la lista ordinata dei documenti recuperati.

Per ogni posizione i viene calcolata la precisione parziale:

$$P(i) = \frac{\sum_{j=1}^{i} rel(j)}{i}$$

L'Average Precision viene quindi definita come:

$$AP = \frac{\sum_{i=1}^{n} P(i) \cdot rel(i)}{|Relevant|}$$

dove:

- $P(i)$ rappresenta la precisione fino alla posizione i;
- $rel(i)$ vale 1 se il documento in posizione i è rilevante;
- $|Relevant|$ è il numero totale di documenti rilevanti.

L'AP assume valore massimo pari a:

$$AP = 1$$

quando tutti i documenti rilevanti compaiono prima di qualsiasi documento non rilevante.

L'AP è particolarmente adatta alla valutazione di sistemi RAG poiché premia i chunk rilevanti che compaiono nelle prime posizioni del ranking.

4.4 Mean Average Precision (MAP)

La Mean Average Precision rappresenta la metrica principale utilizzata per confrontare le diverse configurazioni della pipeline.

Indicando con:

$$Q$$

il numero totale delle query valutate, si definisce:

$$MAP = \frac{1}{Q} \sum_{q=1}^{Q} AP_q$$

dove:

$$AP_q$$

è l'Average Precision associata alla query q.

La MAP sintetizza in un unico valore la qualità complessiva del sistema di retrieval.

4.5 Discounted Cumulative Gain (DCG)

Per valutare la qualità del ranking viene utilizzata la metrica Discounted Cumulative Gain.

Nel sistema ogni documento rilevante possiede guadagno unitario:

$$rel_i \in \{0, 1\}$$

Il DCG viene definito come:

$$DCG@k = \sum_{i=1}^{k} \frac{rel_i}{\log_2(i+1)}$$

La presenza del termine logaritmico penalizza progressivamente i documenti rilevanti collocati nelle posizioni più basse del ranking.

Di conseguenza, recuperare un documento rilevante in prima posizione produce un contributo maggiore rispetto al recupero dello stesso documento nelle ultime posizioni.

4.6 Normalized Discounted Cumulative Gain (nDCG)

Per consentire il confronto tra query differenti viene utilizzata la versione normalizzata del DCG.

Si definisce innanzitutto:

$$IDCG@k$$

come il valore del DCG ottenibile nel caso di ranking perfetto.

La metrica finale è:

$$nDCG@k = \frac{DCG@k}{IDCG@k}$$

con:

$$0 \leq nDCG@k \leq 1$$

Il valore massimo viene raggiunto quando tutti i documenti rilevanti occupano le prime posizioni disponibili del ranking.

4.7 Valutazione Granulare e MAP per Domanda Madre

Nella valutazione granulare una domanda complessa viene suddivisa in più sotto-domande.

Indicando con:

$$S_p = \{s_1, s_2, \ldots, s_m\}$$

l'insieme delle sotto-domande appartenenti alla stessa domanda madre p, viene calcolata una MAP specifica:

$$MAP_p = \frac{1}{m} \sum_{i=1}^{m} AP_i$$

dove:

$$AP_i$$

rappresenta l'Average Precision della singola sotto-domanda.

Questa misura permette di valutare la capacità del sistema di recuperare correttamente le informazioni necessarie per rispondere ad una domanda articolata composta da più aspetti informativi.

4.8 Valutazione delle Pipeline Multi-Query

Per le configurazioni basate sulla decomposizione della query viene considerato un insieme di sotto-domande:

$$Q = \{q_1, q_2, \ldots, q_m\}$$

Ad ogni sotto-domanda corrisponde un insieme di chunk rilevanti:

$$G_i$$

L'insieme globale dei documenti rilevanti viene costruito come:

$$G = \bigcup_{i=1}^{m} G_i$$

Tale insieme viene utilizzato per confrontare le differenti modalità operative:

- Whole Question;
- Rerank Once;
- Rerank Each;
- Random Baseline.

Per ciascuna strategia vengono calcolate:

$$AP, \quad MAP, \quad Precision@k, \quad Recall@k, \quad nDCG@k.$$

Questa procedura consente di verificare se la decomposizione della domanda incrementa la copertura dei documenti rilevanti rispetto all'utilizzo della sola query originale.

4.9 Baseline Random

Per valutare l'effettivo contributo del retrieval viene confrontato il sistema con una baseline casuale.

La baseline seleziona uniformemente:

$$k = 20$$

chunk dal corpus, ignorando completamente la query.

Quando la baseline viene eseguita su più seed differenti si calcolano:

$$\mu = \frac{1}{n} \sum_{i=1}^{n} x_i$$

e

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (x_i - \mu)^2}$$

dove:

- μ rappresenta la media delle metriche;
- σ rappresenta la deviazione standard;
- n è il numero di seed utilizzati.

4.10 Valori Attesi della Baseline Random

Assumendo un corpus composto da:

$$N$$

documenti totali e

$$R$$

documenti rilevanti, la baseline casuale possiede i seguenti valori attesi.
Per la precisione:

$$\mathbb{E}[Precision@k] = \frac{R}{N}$$

mentre per la recall:

$$\mathbb{E}[Recall@k] = \frac{k}{N}$$

con:

$$k \leq N.$$

Questi valori teorici vengono utilizzati come riferimento per verificare che il sistema proposto fornisca prestazioni significativamente superiori al recupero casuale.

Questa sezione è già pronta per una tesi magistrale o un paper e riflette fedelmente le metriche implementate nel codice di valutazione.

4.11 Generazione della Risposta

I chunk selezionati vengono utilizzati come contesto per un modello linguistico locale basato su Qwen.

La generazione è vincolata esclusivamente ai documenti recuperati dalla pipeline di retrieval.

5 Confronto tra gli Esperimenti

Per isolare l'effetto dei singoli componenti, i confronti sono stati organizzati in gruppi sperimentali distinti.

5.1 Esperimenti A1 vs A2

Questo confronto ha l'obiettivo di misurare esclusivamente l'impatto del retriever.

Le condizioni mantenute costanti sono:

- stessa strategia di chunking;
- stesso corpus;
- stesso ground truth granulare;
- assenza di decomposizione.

5.2 Esperimenti B1 vs B2

Questo confronto misura l'effetto della decomposizione delle query.

Sono mantenuti costanti:

- retriever;
- chunking;
- corpus;
- ground truth aggregato.

Table 1: Confronto B1 vs B2.

Retriever	Chunking	MAP B1	MAP B2	Δ MAP

6 Interpretazione dei Grafici

I grafici sono stati costruiti utilizzando esclusivamente i risultati ottenuti dalle valutazioni IR.

6.1 Grafici di Ranking

L'obiettivo è identificare:

- le configurazioni migliori;
- la robustezza rispetto al chunking;
- il contributo dei diversi retriever.

6.2 Grafici Chunking vs Retriever

Per ogni retriever vengono confrontate le strategie:

- Fixed;
- Sliding;
- Hybrid.

Lo scopo è determinare quale segmentazione produce il miglior recupero dell'informazione.

6.3 Grafici B1 vs B2

I grafici B1/B2 consentono di quantificare l'effetto della decomposizione delle query.

Un incremento positivo di MAP indica che la decomposizione ha migliorato la copertura dei chunk rilevanti.

6.4 Grafici delle Metriche al variare di k

Per ogni configurazione vengono analizzate:

- Precision@k;
- Recall@k;
- nDCG@k.

L'analisi congiunta permette di capire se il sistema privilegia:

- accuratezza dei primi risultati;
- copertura globale;
- qualità del ranking.

7 Risultati

7.1 COMPAS

La Tabella 2 riporta le cinque configurazioni con MAP più elevata. Tutte utilizzano la strategia di chunking `sliding` e un ground truth granulare. I risultati mostrano che la combinazione di retrieval denso BGE ed E5 raggiunge la MAP più alta, mentre la configurazione ibrida BM25+BGE presenta la migliore copertura delle query.

Table 2: Le cinque migliori configurazioni RAG per MAP sul dataset C_COMPAS.

Configurazione	MAP	Hit@20 (%)	Query con AP nulla	Rapporto random
`dense_bge_e5`	0.3378	85.0	3/20	5.23×
`bm25_bge`	0.3247	100.0	0/20	5.02×
`single_bge`	0.3133	90.0	2/20	4.85×
`single_e5`	0.2909	80.0	4/20	4.50×
`bm25_e5`	0.2877	75.0	5/20	4.45×

La configurazione `dense_bge_e5` con chunking `sliding` raggiunge una MAP pari a 0.3378, risultando la migliore tra quelle valutate. Rispetto alla baseline casuale, la cui MAP media è pari a 0.0646, il miglioramento assoluto è di 0.2732, corrispondente a un valore circa 5.23 volte superiore al riferimento. Questo risultato suggerisce che l'integrazione delle rappresentazioni dense di BGE ed E5 consenta di ottenere un ordinamento complessivamente efficace dei documenti rilevanti.

La configurazione `bm25_bge` raggiunge invece una MAP pari a 0.3247 e un Hit@20 del 100%, senza query con Average Precision nulla. Il sistema recupera quindi almeno un documento rilevante per ciascuna delle venti query valutate. Sebbene la MAP sia leggermente inferiore a quella di `dense_bge_e5`, la maggiore copertura rappresenta un vantaggio importante nelle applicazioni in cui è prioritario evitare query senza risultati pertinenti.

La differenza tra i due sistemi evidenzia che la scelta della configurazione ottimale dipende dall'obiettivo applicativo. Se si intende massimizzare la qualità media del ranking, `dense_bge_e5` costituisce la scelta migliore; se si privilegia la copertura delle query, `bm25_bge` presenta risultati più favorevoli in termini di Hit@20.

7.1.1 Effetto della strategia di chunking

La Tabella 3 confronta i valori di MAP ottenuti dai diversi retriever con le tre strategie di segmentazione. Per ogni metodo, `sliding` presenta il valore più elevato, mentre `hybrid` mostra il risultato più basso.

Table 3: Confronto della MAP tra retriever e strategie di chunking.

Retriever	Fixed	Sliding	Hybrid	Media
bm25_bge	0.2434	0.3247	0.1781	0.2487
bm25_e5	0.2122	0.2877	0.1416	0.2138
dense_bge_e5	0.2840	0.3378	0.1729	0.2649
single_bge	0.2681	0.3133	0.1573	0.2462
single_bm25	0.1629	0.2112	0.1003	0.1581
single_e5	0.1877	0.2909	0.1065	0.1950

L'analisi evidenzia che `sliding` è la strategia più efficace per tutti e sei i retriever considerati. La configurazione `dense_bge_e5` raggiunge una MAP di 0.3378 con `sliding`, rispetto a 0.2840 con `fixed` e 0.1729 con `hybrid`. Il passaggio da `fixed` a `sliding` determina un incremento assoluto di 0.0538, mentre il vantaggio rispetto a `hybrid` è pari a 0.1649.

Un andamento analogo si osserva per gli altri retriever. Ad esempio, `single_e5` passa da una MAP di 0.1877 con `fixed` a 0.2909 con `sliding`, mentre `bm25_bge` migliora da 0.2434 a 0.3247. Al contrario, la strategia `hybrid` presenta i risultati inferiori per tutti i sistemi analizzati.

Questa evidenza è coerente con l'ipotesi che la sovrapposizione tra finestre di testo consenta di conservare una maggiore quantità di contesto, riducendo il rischio che informazioni semanticamente collegate vengano separate tra chunk distinti. La strategia `hybrid`, pur essendo progettata per rispettare la struttura documentale, potrebbe invece generare segmenti meno favorevoli alle query considerate.

È tuttavia necessario evitare un'interpretazione causale diretta. Le strategie di chunking producono corpus di dimensioni differenti e segmenti con lunghezze diverse; pertanto, il vantaggio osservato per `sliding` potrebbe dipendere anche da queste caratteristiche. Inoltre, il report segnala che ground truth e corpus possono variare tra le strategie. Le medie riportate devono quindi essere interpretate come descrittive del confronto sperimentale.

7.1.2 Caratteristiche dei chunk

Le statistiche relative ai chunk permettono di approfondire le differenze tra le strategie di segmentazione e di contestualizzare i risultati del retrieval.

Table 4: Statistiche descrittive dei chunk per strategia di segmentazione.

Strategia	N. chunk	Media caratteri	Mediana	Massimo	Con tabelle (%)
`fixed`	74	483.0	512	1749	10.8
`hybrid`	74	504.9	512	1951	10.8
`sliding`	57	708.4	668	1896	14.0

La strategia `sliding` genera 57 chunk, contro i 74 prodotti da `fixed` e `hybrid`. I segmenti `sliding` sono inoltre più lunghi: la lunghezza media è pari a 708.4 caratteri, rispetto a 483.0 per `fixed` e 504.9 per `hybrid`. Anche la mediana è superiore, passando da 512 caratteri per le prime due strategie a 668 caratteri per `sliding`.

La percentuale di chunk contenenti tabelle è pari al 14.0% per `sliding`, contro il 10.8% delle altre due strategie. Queste differenze suggeriscono che la strategia `sliding` possa conservare porzioni di contesto più ampie, comprese informazioni strutturate, favorendo il recupero dei contenuti pertinenti.

Il numero di chunk, la loro lunghezza e la percentuale di segmenti contenenti tabelle non sono tuttavia sufficienti per stabilire quale caratteristica determini il miglioramento. Per isolare l'effetto della sovrapposizione sarebbe necessario confrontare strategie con lunghezza media e corpus comparabili, mantenendo costanti il ground truth e le altre componenti della pipeline.

7.1.3 Confronto con la baseline casuale

Per valutare il vantaggio dei sistemi di retrieval rispetto a un riferimento privo di una strategia di ordinamento informata, il report confronta le MAP osservate con quelle ottenute tramite baseline casuale. La Tabella 5 riporta i risultati delle cinque migliori configurazioni.

Table 5: Confronto tra le migliori configurazioni e la baseline casuale.

Configurazione	**MAP reale**	**MAP random**	**Δ MAP**	**Rapporto**
`dense_bge_e5`, sliding	0.3378	0.0646 ± 0.0158	0.2732	5.23×
`bm25_bge`, sliding	0.3247	0.0646 ± 0.0158	0.2600	5.02×
`single_bge`, sliding	0.3133	0.0646 ± 0.0158	0.2487	4.85×
`single_e5`, sliding	0.2909	0.0646 ± 0.0158	0.2263	4.50×
`bm25_e5`, sliding	0.2877	0.0646 ± 0.0158	0.2231	4.45×

Il confronto mostra che tutte le configurazioni riportate nella tabella superano sensibilmente il riferimento casuale. La MAP osservata è compresa tra 0.2877 e 0.3378, mentre la baseline corrispondente presenta una media pari a 0.0646 e una deviazione standard di 0.0158. Il sistema `dense_bge_e5` con chunking `sliding` raggiunge una MAP circa 5.23 volte superiore al riferimento, con un incremento assoluto di 0.2732.

Anche le configurazioni `bm25_bge` e `single_bge` mostrano risultati nettamente superiori alla baseline, con rapporti rispettivamente pari a 5.02 e 4.85. Il vantaggio rispetto al riferimento casuale emerge quindi in più configurazioni e non dipende esclusivamente da un singolo metodo di retrieval.

7.1.4 Analisi delle query

L'analisi aggregata delle metriche non descrive completamente il comportamento del sistema sulle singole query. Per questo motivo, il report individua le domande per le quali la configurazione migliore, `dense_bge_e5` con chunking `sliding`, presenta le prestazioni più basse.

Table 6: Query più difficili per la configurazione `dense_bge_e5` con chunking `sliding`.

ID	Informazione richiesta	AP	N. rilevanti
D2.1	Timeframe of data collection	0.000	1
D4.1	Available features and their explanation	0.000	4
D5.5	Label provenance	0.000	1
D6.3	Severity of inaccuracy	0.062	2
D4.4	Assumptions about data representation	0.083	2
D5.1	Attributes salient or at risk of discrimination	0.091	2
D1.2	Actors involved in data collection	0.160	3
D5.2	Marginal distribution of protected attributes	0.167	2

Le query D2.1, D4.1 e D5.5 presentano un'Average Precision pari a zero. Esse riguardano rispettivamente il periodo di raccolta dei dati, le variabili disponibili e la loro descrizione, e la provenienza delle etichette. Nel caso di D4.1, il ground truth comprende quattro elementi rilevanti, mentre per D2.1 e D5.5 è presente un solo elemento rilevante.

Questi risultati evidenziano alcune difficoltà nel recupero di informazioni specifiche. Una possibile spiegazione è che i contenuti richiesti siano espressi nei documenti con terminologia diversa da quella della query oppure siano distribuiti tra più sezioni. Le informazioni relative alle variabili disponibili e alla provenienza delle etichette potrebbero inoltre richiedere l'identificazione di relazioni semantiche o di contenuti strutturati che non vengono catturati adeguatamente dalla similarità tra embedding.

Le query D6.3 e D4.4 presentano invece valori di AP pari rispettivamente a 0.062 e 0.083, indicando una qualità di ranking limitata. Le query D1.2 e D5.2 mostrano valori relativamente superiori, ma restano al di sotto delle prestazioni medie della configurazione.

7.1.5 Conclusioni COMPAS

Nel complesso, i risultati ottenuti sul dataset C_COMPAS indicano che la qualità del retrieval dipende congiuntamente dalla scelta del retriever e dalla strategia di segmentazione del documento. La configurazione `dense_bge_e5` con chunking `sliding` rappresenta la soluzione migliore in termini di MAP, con un valore pari a 0.3378 e un incremento di 0.2732 rispetto alla baseline casuale. La configurazione `bm25_bge`, pur presentando una MAP leggermente inferiore, garantisce un Hit@20 del 100%, mostrando una copertura completa delle query valutate.

La strategia `sliding` risulta la più efficace per tutti i retriever analizzati, mentre `hybrid` presenta le prestazioni inferiori nell'esperimento considerato. Il vantaggio di `sliding` è coerente con la possibilità di preservare una maggiore quantità di contesto nei segmenti recuperati; tuttavia, il diverso numero di chunk e la diversa lunghezza dei segmenti impediscono di attribuire tale vantaggio alla sola sovrapposizione delle finestre.

L'analisi delle singole query mostra inoltre che alcune informazioni specifiche, quali il periodo di raccolta dei dati, la descrizione delle variabili e la provenienza delle etichette, rimangono difficili da recuperare anche con la configurazione complessivamente migliore. Un possibile sviluppo consiste quindi nell'integrare il retrieval denso con quello lessicale e nel valutare strategie di decomposizione e reranking, verificandone l'efficacia mediante confronti controllati.

In conclusione, se l'obiettivo prioritario è massimizzare la qualità complessiva del ranking, i risultati suggeriscono di preferire `dense_bge_e5` con chunking `sliding`. Se invece è fondamentale garantire che ogni query recuperi almeno un documento pertinente, `bm25_bge` con la stessa strategia di chunking costituisce un'alternativa particolarmente interessante. Queste conclusioni restano circoscritte alle configurazioni, alle query e ai ground truth utilizzati nell'esperimento

e dovrebbero essere confermate su ulteriori valutazioni prima di essere generalizzate ad altri dataset.

7.2 D_German

La Tabella 7 riporta le cinque configurazioni RAG con MAP più elevata sul dataset D_German. A differenza dei risultati ottenuti sul dataset C_COMPAS, tutte le prime sei configurazioni utilizzano la strategia di chunking `fixed`. La configurazione `bm25_bge` raggiunge la MAP più elevata, pari a 0.4619, seguita da `bm25_e5` e `dense_bge_e5`, con valori rispettivamente pari a 0.4604 e 0.4570. I risultati mostrano che, per questo dataset, la segmentazione a lunghezza fissa favorisce tutte le famiglie di retriever considerate. La configurazione `single_bge` presenta invece il miglior valore di Hit@20 tra le prime cinque, pari al 95.5%, con una sola query caratterizzata da Average Precision nulla.

Table 7: Le cinque migliori configurazioni RAG per MAP sul dataset D_German.

Configurazione	MAP	Hit@20 (%)	Query con AP nulla	Rapporto random
`bm25_bge`	0.4619	90.9	2/22	5.88×
`bm25_e5`	0.4604	81.8	4/22	5.86×
`dense_bge_e5`	0.4570	86.4	3/22	5.81×
`single_bge`	0.4454	95.5	1/22	5.67×
`single_e5`	0.4385	81.8	4/22	5.58×

La configurazione `bm25_bge` con chunking `fixed` raggiunge una MAP pari a 0.4619, risultando la migliore tra le diciotto configurazioni valutate. Rispetto alla baseline casuale, la cui MAP media è pari a 0.0786 ± 0.0230, il miglioramento assoluto è di 0.3833, corrispondente a un valore circa 5.88 volte superiore al riferimento. Il risultato suggerisce che l'integrazione del recupero lessicale BM25 con le rappresentazioni dense BGE consenta di combinare la capacità di identificare corrispondenze terminologiche con quella di recuperare contenuti semanticamente affini.

Le differenze tra le prime tre configurazioni sono tuttavia contenute. `bm25_e5` raggiunge una MAP di 0.4604, mentre `dense_bge_e5` ottiene 0.4570. Lo scarto tra il primo e il terzo sistema è quindi pari a soli 0.0049. Questo risultato indica che, in presenza della strategia `fixed`, sia l'integrazione tra retrieval lessicale e denso sia l'impiego congiunto di rappresentazioni dense possono produrre ranking competitivi. I dati non consentono tuttavia di concludere che le differenze osservate siano statisticamente significative.

Un aspetto rilevante emerge confrontando la MAP con l'Hit@20. La configurazione `single_bge`, pur raggiungendo una MAP inferiore a quella dei tre sistemi precedenti, presenta un Hit@20 del 95.5% e una sola query con AP nulla. Il sistema recupera quindi almeno un documento rilevante per 21 delle 22 query valutate. Al contrario, `bm25_bge` raggiunge una MAP superiore, ma presenta due query con AP nulla e un Hit@20 del 90.9%.

La differenza tra questi sistemi evidenzia che la scelta della configurazione ottimale dipende dall'obiettivo applicativo. Se si intende massimizzare la qualità media del ranking, `bm25_bge` costituisce la scelta migliore. Se invece si privilegia la copertura delle query e si vuole ridurre il numero di domande per le quali il sistema non recupera alcun documento pertinente, `single_bge` rappresenta un'alternativa interessante.

7.2.1 Effetto della strategia di chunking

La Tabella 8 confronta i valori di MAP ottenuti dai sei retriever con le tre strategie di segmentazione. Per tutti i retriever considerati, la strategia `fixed` produce il risultato migliore, mentre

hybrid presenta la MAP più bassa. Questo andamento è opposto a quello osservato sul dataset C_COMPAS, nel quale la strategia sliding risultava la più efficace.

Table 8: Confronto della MAP tra retriever e strategie di chunking sul dataset D_German.

Retriever	Fixed	Sliding	Hybrid	Media
bm25_bge	0.4619	0.2557	0.2267	0.3148
bm25_e5	0.4604	0.2496	0.2358	0.3153
dense_bge_e5	0.4570	0.3090	0.2261	0.3307
single_bge	0.4454	0.2987	0.2035	0.3159
single_bm25	0.3820	0.2151	0.2018	0.2663
single_e5	0.4385	0.2820	0.2179	0.3128

L'analisi evidenzia che fixed è la strategia più efficace per tutti e sei i retriever analizzati. La configurazione bm25_bge raggiunge una MAP di 0.4619 con fixed, rispetto a 0.2557 con sliding e 0.2267 con hybrid. Il passaggio da fixed a sliding determina quindi una riduzione assoluta della MAP pari a 0.2062, mentre la differenza rispetto a hybrid raggiunge 0.2352.

Un andamento analogo si osserva per gli altri sistemi. La configurazione dense_bge_e5 passa da una MAP di 0.4570 con fixed a 0.3090 con sliding e 0.2261 con hybrid. Anche single_e5 mostra un calo consistente, passando da 0.4385 a 0.2820 e 0.2179. La strategia fixed risulta pertanto vantaggiosa indipendentemente dalla famiglia di retrieval impiegata.

La media descrittiva più elevata tra i retriever è quella di dense_bge_e5, pari a 0.3307. Seguono single_bge, con 0.3159, e bm25_e5, con 0.3153. Questa media deve essere interpretata con cautela, poiché i valori aggregati mettono a confronto strategie che possono differire per composizione del corpus e ground truth. Inoltre, la media non rappresenta una configurazione effettivamente eseguita, ma un riepilogo descrittivo delle tre strategie di chunking.

Il vantaggio di fixed suggerisce che, per il dataset D_German, la segmentazione a lunghezza fissa possa produrre unità informative particolarmente adatte alle query valutate. Una possibile interpretazione è che segmenti di dimensione più uniforme facilitino l'associazione tra le informazioni richieste e i contenuti recuperati. La sovrapposizione delle finestre di sliding, invece, potrebbe introdurre ridondanza oppure distribuire le informazioni rilevanti in segmenti meno favorevoli al ranking.

Queste spiegazioni devono tuttavia essere considerate ipotesi interpretative, non conclusioni causali. Le differenze osservate potrebbero dipendere anche dalla lunghezza dei chunk, dalla distribuzione delle informazioni nel documento, dal numero di segmenti prodotti e dalle modalità con cui è stato costruito il ground truth. Per isolare l'effetto della strategia di segmentazione sarebbe necessario mantenere costanti le altre componenti della pipeline e utilizzare un ground truth comparabile tra le configurazioni.

7.2.2 Caratteristiche dei chunk

Le statistiche relative ai chunk permettono di contestualizzare i risultati del retrieval e di approfondire le differenze tra le strategie di segmentazione utilizzate sul dataset D_German.

Table 9: Statistiche descrittive dei chunk per strategia di segmentazione sul dataset D_German.

Strategia	N. chunk	Media caratteri	Mediana	Massimo	Con tabelle (%)
`fixed`	54	499.8	512	1366	11.1
`hybrid`	54	522.3	512	1568	11.1
`sliding`	49	665.0	613	1641	12.2

La strategia `fixed` produce 54 chunk, lo stesso numero ottenuto con `hybrid`, mentre `sliding` genera 49 segmenti. I chunk `fixed` presentano una lunghezza media di 499.8 caratteri e una mediana di 512 caratteri. Per `hybrid`, la media sale a 522.3 caratteri, mentre la mediana rimane pari a 512. La strategia `sliding` genera invece segmenti più lunghi, con una media di 665.0 caratteri e una mediana di 613 caratteri.

La lunghezza massima è pari a 1366 caratteri per `fixed`, 1568 per `hybrid` e 1641 per `sliding`. Anche la percentuale di chunk contenenti tabelle è leggermente superiore per `sliding`, pari al 12.2%, rispetto all'11.1% delle altre due strategie.

Queste differenze mostrano che le strategie non producono soltanto segmentazioni differenti, ma anche unità testuali con caratteristiche dimensionali diverse. In particolare, `sliding` produce meno chunk, ma mediamente più lunghi. Ciò può influire sul retrieval, poiché la quantità di testo contenuta in ciascun segmento determina il livello di granularità con cui le informazioni vengono indicizzate e recuperate.

Nel dataset D_German, tuttavia, i chunk più lunghi di `sliding` non si traducono in prestazioni superiori. Al contrario, la strategia `fixed` ottiene i risultati migliori per tutti i retriever. Questo dato suggerisce che, nel caso analizzato, una segmentazione più uniforme possa risultare più adatta alla localizzazione delle informazioni rilevanti rispetto a finestre più ampie e sovrapposte.

Non è però possibile attribuire il vantaggio di `fixed` esclusivamente alla lunghezza dei segmenti. Per stabilire se il risultato dipenda dalla granularità, dalla sovrapposizione o dalla struttura dei contenuti sarebbe necessario condurre ulteriori esperimenti controllati, mantenendo comparabili il numero di chunk, la lunghezza media e il ground truth.

7.2.3 Confronto con la baseline casuale

Per valutare il vantaggio dei sistemi di retrieval rispetto a un ordinamento non informato, il report confronta le MAP osservate con quelle ottenute mediante una baseline casuale. La Tabella 10 riporta le cinque migliori configurazioni e i relativi miglioramenti rispetto al riferimento.

Table 10: Confronto tra le migliori configurazioni RAG e la baseline casuale sul dataset D_German.

Configurazione	MAP reale	MAP random	Δ MAP	Rapporto
`bm25_bge`, fixed	0.4619	0.0786 ± 0.0230	0.3833	5.88×
`bm25_e5`, fixed	0.4604	0.0786 ± 0.0230	0.3818	5.86×
`dense_bge_e5`, fixed	0.4570	0.0786 ± 0.0230	0.3784	5.81×
`single_bge`, fixed	0.4454	0.0786 ± 0.0230	0.3668	5.67×
`single_e5`, fixed	0.4385	0.0786 ± 0.0230	0.3599	5.58×

Il confronto mostra che tutte le cinque configurazioni superano sensibilmente la baseline casuale. La MAP osservata è compresa tra 0.4385 e 0.4619, mentre il riferimento casuale presenta una media di 0.0786 e una deviazione standard di 0.0230, calcolate su dieci seed. La configurazione `bm25_bge` con chunking `fixed` raggiunge una MAP circa 5.88 volte superiore al riferimento, con un incremento assoluto di 0.3833.

Anche `bm25_e5` e `dense_bge_e5` mostrano prestazioni nettamente superiori alla baseline, con rapporti rispettivamente pari a 5.86 e 5.81. La differenza tra i valori di MAP dei tre sistemi migliori è contenuta, confermando che più configurazioni sono in grado di ottenere risultati competitivi sul dataset D_German.

Il vantaggio rispetto alla baseline casuale non riguarda esclusivamente il miglior sistema, ma caratterizza l'intero gruppo delle configurazioni basate su `fixed`. Anche `single_bge` e `single_e5` raggiungono rapporti superiori a 5.5, indicando che il retrieval denso, anche senza la combinazione esplicita con BM25, permette di ottenere ranking significativamente migliori del riferimento casuale in termini descrittivi.

I risultati relativi alle altre strategie di chunking confermano inoltre un vantaggio rispetto alla baseline, sebbene più contenuto. Per esempio, `dense_bge_e5` con `sliding` raggiunge una MAP di 0.3090, pari a circa 3.42 volte il riferimento casuale corrispondente. Con `hybrid`, la stessa famiglia di retrieval raggiunge invece una MAP di 0.2261, pari a circa 2.66 volte la baseline.

Nel complesso, il confronto suggerisce che la qualità del ranking dipenda in misura rilevante dall'interazione tra retriever e strategia di segmentazione. La baseline casuale costituisce un riferimento utile per quantificare il miglioramento, ma non sostituisce un test statistico di significatività. Inoltre, il confronto deve tenere conto del fatto che le baseline riportate differiscono tra strategie di chunking, con valori medi pari a 0.0786 per `fixed`, 0.0902 per `sliding` e 0.0851 per `hybrid`.

7.2.4 Analisi delle query

Le metriche aggregate non descrivono completamente il comportamento del sistema sulle singole query. Per questo motivo, il report individua le domande per le quali la configurazione migliore, `bm25_bge` con chunking `fixed`, presenta i valori di Average Precision più bassi.

Table 11: Query più difficili per la configurazione `bm25_bge` con chunking `fixed`.

ID	Informazione richiesta	AP	N. rilevanti
D1.1	Purpose for original data collection	0.000	1
D2.2	Geographical area	0.000	2
D4.1	Available features	0.042	3
D3.1	Sampling strategy	0.050	2
D4.4	Assumptions about representation	0.100	2
D6.2	Gaps in the data	0.179	2
D5.1	Attributes at risk	0.188	2
D1.2	People and organizations involved	0.216	2

Le query D1.1 e D2.2 presentano un'Average Precision pari a zero. La prima riguarda lo scopo originario della raccolta dei dati, mentre la seconda richiede di identificare l'area geografica di riferimento. Nel primo caso il ground truth comprende un solo elemento rilevante; nel secondo sono presenti due elementi rilevanti. Il sistema non riesce quindi a collocare correttamente alcun elemento rilevante ai fini della metrica AP per queste due query.

La query D4.1, relativa alle caratteristiche disponibili del dataset, raggiunge una AP pari a 0.042, nonostante il ground truth comprenda tre elementi rilevanti. Anche D3.1, relativa alla strategia di campionamento, presenta un risultato limitato, con AP pari a 0.050. Queste prestazioni indicano che il recupero di informazioni metodologiche specifiche può rimanere difficoltoso anche quando il sistema raggiunge una MAP complessiva elevata.

Le query D4.4 e D6.2, relative rispettivamente alle assunzioni sulla rappresentazione dei dati e alle lacune presenti nel dataset, mostrano valori di AP pari a 0.100 e 0.179. Anche la query D5.1, relativa agli attributi potenzialmente a rischio, raggiunge una AP pari a 0.188. Questi risultati suggeriscono che alcune informazioni richiedano un recupero più articolato, potenzialmente influenzato dalla terminologia impiegata nel documento e dalla distribuzione dei contenuti tra sezioni differenti.

La query D1.2, relativa alle persone e alle organizzazioni coinvolte nella raccolta dei dati, presenta il valore più elevato tra le query elencate, con AP pari a 0.216. Il risultato rimane comunque inferiore alla MAP complessiva della configurazione, pari a 0.4619. È opportuno ricordare che l'AP di una singola query e la MAP aggregata misurano aspetti differenti: la seconda rappresenta la media delle AP sulle query valutate, mentre la prima descrive il comportamento del ranking per una specifica domanda.

Nel complesso, le query più difficili riguardano informazioni descrittive e metodologiche, come lo scopo della raccolta, l'area geografica, le variabili disponibili e il metodo di campionamento. Una possibile linea di miglioramento consiste nel combinare il recupero lessicale e quello semantico con tecniche di decomposizione delle domande e reranking. Ad esempio, la query relativa alle caratteristiche disponibili potrebbe essere scomposta in richieste distinte per identificare i nomi delle variabili e le rispettive descrizioni.

Tali interventi dovrebbero essere valutati sperimentalmente, verificando se producano miglioramenti sulle query più difficili senza compromettere le prestazioni complessive del sistema.

7.2.5 Conclusioni D_German

Nel complesso, i risultati ottenuti sul dataset D_German mostrano che la qualità del retrieval dipende congiuntamente dalla scelta del retriever e dalla strategia di segmentazione del documento. La configurazione `bm25_bge` con chunking `fixed` rappresenta la soluzione migliore in termini di MAP, con un valore pari a 0.4619 e un incremento assoluto di 0.3833 rispetto alla baseline casuale. La prestazione è circa 5.88 volte superiore al riferimento, evidenziando l'efficacia della combinazione tra recupero lessicale e rappresentazioni dense BGE.

Le configurazioni `bm25_e5` e `dense_bge_e5`, anch'esse basate su `fixed`, ottengono MAP rispettivamente pari a 0.4604 e 0.4570. La ridotta differenza rispetto al primo classificato indica che non emerge un unico vantaggio netto del retrieval ibrido BM25+BGE rispetto alle altre combinazioni valutate. La configurazione `single_bge` presenta invece l'Hit@20 più elevato tra le prime cinque, pari al 95.5%, mostrando un vantaggio in termini di copertura delle query.

La strategia `fixed` risulta la più efficace per tutti i sei retriever considerati, mentre `hybrid` presenta le prestazioni inferiori. Il risultato è particolarmente significativo nel confronto con C_COMPAS, per il quale `sliding` aveva mostrato prestazioni superiori. Questa differenza suggerisce che non esista una strategia di chunking universalmente migliore: la scelta ottimale può dipendere dalla struttura del documento, dalla distribuzione delle informazioni e dalle caratteristiche delle query.

Le statistiche sui chunk mostrano che `fixed` produce 54 segmenti con una lunghezza media di 499.8 caratteri, mentre `sliding` genera 49 segmenti con una lunghezza media di 665.0 caratteri. La maggiore lunghezza dei segmenti `sliding` non determina, in questo caso, un miglioramento del retrieval. Una possibile interpretazione è che una segmentazione più uniforme favorisca la localizzazione delle informazioni rilevanti; tuttavia, questa ipotesi richiede ulteriori verifiche sperimentali.

L'analisi delle singole query evidenzia inoltre che alcune informazioni metodologiche e descrittive rimangono difficili da recuperare anche con la configurazione complessivamente migliore. In particolare, le query relative allo scopo della raccolta dei dati e all'area geografica presentano AP nulla, mentre quelle riguardanti le variabili disponibili e la strategia di campionamento mostrano valori di AP molto bassi. Un possibile sviluppo consiste nell'integrare il retrieval ibrido con

strategie di decomposizione e reranking, valutandone l'efficacia mediante esperimenti controllati sulle query problematiche.

In conclusione, per il dataset D_German i risultati suggeriscono di preferire `bm25_bge` con chunking `fixed` quando l'obiettivo prioritario è massimizzare la qualità complessiva del ranking. Se invece è fondamentale aumentare la probabilità di recuperare almeno un documento pertinente per ogni query, `single_bge` con la medesima strategia di segmentazione costituisce un'alternativa interessante. Queste conclusioni restano circoscritte alle configurazioni, alle query e ai ground truth utilizzati nell'esperimento e dovrebbero essere confermate su ulteriori valutazioni prima di essere generalizzate ad altri dataset.

7.3 B_Adult

La Tabella 12 riporta le cinque migliori configurazioni RAG in termini di Mean Average Precision (MAP) sul dataset B_Adult, considerando il gruppo sperimentale con ground truth granulare. I risultati mostrano una netta prevalenza delle configurazioni basate su retrieval denso e sulla strategia di chunking `fixed`. La configurazione `dense_bge_e5` raggiunge la MAP più elevata, pari a 0.5355, seguita da `single_e5`, con 0.5317, e `dense_bgem3_e5`, con 0.5251.

Le prime cinque configurazioni utilizzano tutte la strategia `fixed` e ottengono valori di MAP compresi tra 0.5197 e 0.5355. Questo risultato evidenzia la competitività delle rappresentazioni dense sul dataset considerato e suggerisce che una segmentazione a lunghezza fissa costituisca una scelta favorevole per le configurazioni con le prestazioni più elevate. La configurazione `single_bge` presenta inoltre il miglior valore di Hit@20 tra le prime cinque, pari al 90.5%, con soltanto due query caratterizzate da Average Precision nulla.

Table 12: Le cinque migliori configurazioni RAG per MAP sul dataset B_Adult con ground truth granulare.

Configurazione	MAP	Hit@20 (%)	Query con AP nulla	Rapporto random
`dense_bge_e5`	0.5355	85.7	3/21	11.48×
`single_e5`	0.5317	81.0	4/21	11.40×
`dense_bgem3_e5`	0.5251	85.7	3/21	11.26×
`single_bgem3`	0.5217	85.7	3/21	11.19×
`single_bge`	0.5197	90.5	2/21	11.14×

La configurazione `dense_bge_e5` con chunking `fixed` raggiunge una MAP pari a 0.5355, risultando la migliore tra le configurazioni valutate nel gruppo con ground truth granulare. Rispetto alla baseline casuale, la cui MAP media è pari a 0.0466 ± 0.0167, il miglioramento assoluto è di 0.4889, corrispondente a un risultato circa 11.48 volte superiore al riferimento. Il dato evidenzia una capacità di ordinamento dei documenti nettamente superiore a quella ottenibile mediante un ranking casuale.

Le prestazioni della configurazione migliore sono strettamente seguite da quelle di `single_e5`, che raggiunge una MAP di 0.5317, e di `dense_bgem3_e5`, con 0.5251. Lo scarto tra la prima e la terza configurazione è pari a 0.0104, mentre la differenza tra il primo e il secondo sistema è di appena 0.0038. Le differenze risultano quindi contenute, soprattutto tra le prime due configurazioni, e non consentono di concludere che le prestazioni osservate siano statisticamente differenti in assenza di test specifici.

Un elemento rilevante riguarda il confronto tra configurazioni dense combinate e retriever singoli. La configurazione `dense_bge_e5` ottiene la MAP più elevata, ma `single_e5` raggiunge un risultato molto vicino pur utilizzando un singolo retriever denso. Analogamente, `single_bgem3` e `single_bge` ottengono rispettivamente MAP pari a 0.5217 e 0.5197. Questi valori suggeriscono che, sul dataset B_Adult, le rappresentazioni dense siano particolarmente efficaci anche senza una combinazione esplicita di più sistemi di retrieval.

La configurazione `single_bge` presenta tuttavia il miglior Hit@20 tra le prime cinque, pari al 90.5%, con due sole query aventi AP nulla. Il sistema recupera quindi almeno un documento rilevante per 19 delle 21 query valutate. Al contrario, `dense_bge_e5`, pur raggiungendo la MAP più elevata, presenta tre query con AP nulla e un Hit@20 dell'85.7%.

La differenza evidenzia che la configurazione ottimale dipende anche dall'obiettivo applicativo. Se si intende massimizzare la qualità media del ranking, `dense_bge_e5` costituisce la scelta migliore. Se invece si privilegia la copertura delle query e si vuole ridurre il numero di domande per le quali il sistema non recupera documenti pertinenti, `single_bge` rappresenta un'alternativa interessante.

7.3.1 Effetto della strategia di chunking

La Tabella 13 confronta i valori di MAP ottenuti dai retriever con le diverse strategie di segmentazione sul dataset B_Adult. Per i sistemi valutati con tutte e tre le strategie, `fixed` produce i risultati migliori, seguito da `hybrid`, mentre `sliding` presenta le prestazioni più basse. Questo andamento è coerente con i risultati osservati sul dataset D_German, per il quale la segmentazione a lunghezza fissa risultava la più efficace per tutti i retriever considerati.

Table 13: Confronto della MAP tra retriever e strategie di chunking sul dataset B_Adult con ground truth granulare.

Retriever	Fixed	Sliding	Hybrid	Media
bm25_bge	0.3632	0.0964	0.2956	0.2517
bm25_e5	0.3640	0.0694	0.3027	0.2454
dense_bge_e5	0.5355	0.1017	0.4563	0.3645
dense_bgem3_e5	0.5251	–	–	0.5251
single_bge	0.5197	0.1166	0.4351	0.3571
single_bgem3	0.5217	–	–	0.5217
single_bm25	0.2570	0.1029	0.2114	0.1904
single_e5	0.5317	0.0917	0.4197	0.3477

L'analisi evidenzia un vantaggio consistente della strategia `fixed` per tutti i retriever per i quali è disponibile il confronto. La configurazione `dense_bge_e5` raggiunge una MAP di 0.5355 con `fixed`, rispetto a 0.1017 con `sliding` e 0.4563 con `hybrid`. Il passaggio da `fixed` a `sliding` determina una riduzione assoluta della MAP pari a 0.4338, mentre la differenza rispetto a `hybrid` è pari a 0.0792.

Un andamento analogo si osserva per `single_bge`, che passa da una MAP di 0.5197 con `fixed` a 0.1166 con `sliding` e 0.4351 con `hybrid`. Anche `single_e5` mostra differenze marcate, con valori rispettivamente pari a 0.5317, 0.0917 e 0.4197. In entrambi i casi, il vantaggio di `fixed` rispetto a `sliding` è superiore a 0.40 punti di MAP.

Le configurazioni basate su BM25 mostrano valori complessivamente inferiori, pur mantenendo lo stesso ordinamento delle strategie di segmentazione. `bm25_e5` raggiunge una MAP di 0.3640 con `fixed`, 0.3027 con `hybrid` e 0.0694 con `sliding`. Per `bm25_bge`, i valori sono rispettivamente pari a 0.3632, 0.2956 e 0.0964. Questi risultati suggeriscono che la strategia di chunking influenzi le prestazioni in misura rilevante anche quando si utilizzano sistemi che combinano il recupero lessicale e quello denso.

La differenza tra `fixed` e `hybrid` risulta particolarmente evidente per i retriever densi. Nel caso di `dense_bge_e5`, il vantaggio di `fixed` è pari a 0.0792, mentre per `single_bge` raggiunge 0.0846 e per `single_e5` è pari a 0.1120. La strategia `hybrid` conserva quindi prestazioni relativamente competitive per questi sistemi, ma non raggiunge i risultati ottenuti con segmenti a lunghezza fissa.

La media descrittiva più elevata tra i retriever per i quali è riportata una sola strategia è quella di `dense_bgem3_e5`, pari a 0.5251. Tuttavia, questo valore coincide con la MAP ottenuta con `fixed`, poiché non sono disponibili risultati per le altre due strategie. Tra i retriever valutati su tutte e tre le strategie, `dense_bge_e5` presenta la media più elevata, pari a 0.3645, seguito da `single_bge`, con 0.3571.

Queste medie devono essere interpretate con cautela, poiché costituiscono riepiloghi descrittivi e mettono a confronto configurazioni che possono differire per composizione del corpus e ground truth. Inoltre, per `dense_bgem3_e5` e `single_bgem3` non sono riportati risultati con `sliding` e `hybrid`; non è quindi possibile confrontarne direttamente la robustezza rispetto alle diverse strategie di segmentazione.

Il vantaggio di `fixed` suggerisce che, per il dataset B_Adult, la segmentazione a lunghezza fissa produca unità informative particolarmente adatte alle query valutate. Una possibile interpretazione è che segmenti di dimensioni relativamente uniformi facilitino l'associazione tra le informazioni richieste e i contenuti recuperati. La strategia `hybrid`, pur rispettando maggiormente la struttura del documento, potrebbe invece produrre unità informative meno favorevoli al ranking per alcune domande. Le finestre sovrapposte di `sliding` potrebbero infine introdurre ridondanza o distribuire le informazioni rilevanti in segmenti meno efficaci.

Queste spiegazioni devono essere considerate ipotesi interpretative e non conclusioni causali. Le differenze osservate potrebbero dipendere anche dalla lunghezza dei chunk, dalla distribuzione delle informazioni nel documento, dal numero di segmenti prodotti e dalle modalità di costruzione del ground truth. Per isolare l'effetto della strategia di segmentazione sarebbe necessario mantenere costanti le altre componenti della pipeline e utilizzare un ground truth comparabile tra le configurazioni.

7.3.2 Caratteristiche dei chunk

Le statistiche relative ai chunk permettono di contestualizzare i risultati del retrieval e di approfondire le differenze tra le strategie di segmentazione utilizzate sul dataset B_Adult.

Table 14: Statistiche descrittive dei chunk per strategia di segmentazione sul dataset B_Adult.

Strategia	N. chunk	Media caratteri	Mediana	Massimo	Con tabelle (%)
`fixed`	63	481.3	512.0	1042	9.5
`hybrid`	63	500.5	512.0	1244	9.5
`sliding`	57	657.5	621.0	1734	10.5

La strategia `fixed` produce 63 chunk, lo stesso numero ottenuto con `hybrid`, mentre `sliding` genera 57 segmenti. I chunk `fixed` presentano una lunghezza media di 481.3 caratteri e una mediana di 512 caratteri. Per `hybrid`, la media sale a 500.5 caratteri, mentre la mediana rimane pari a 512 caratteri. La strategia `sliding` genera invece segmenti mediamente più lunghi, con una media di 657.5 caratteri e una mediana di 621 caratteri.

La lunghezza massima è pari a 1042 caratteri per `fixed`, 1244 per `hybrid` e 1734 per `sliding`. Anche la percentuale di chunk contenenti tabelle è leggermente superiore per `sliding`, pari al 10.5%, rispetto al 9.5% delle altre due strategie.

Le statistiche mostrano che `fixed` e `hybrid` producono lo stesso numero di segmenti, ma differiscono leggermente per lunghezza media e massima. La strategia `sliding`, invece, genera meno

chunk, caratterizzati da dimensioni mediamente maggiori e da una maggiore lunghezza massima. Queste differenze indicano che le strategie non producono soltanto suddivisioni differenti, ma anche unità testuali con caratteristiche dimensionali diverse.

La lunghezza dei segmenti può influire sul retrieval, poiché determina il livello di granularità con cui le informazioni vengono indicizzate e recuperate. Chunk più brevi possono favorire la localizzazione di passaggi specifici, mentre segmenti più lunghi possono preservare una quantità maggiore di contesto. L'effetto concreto dipende tuttavia dal contenuto dei documenti, dalla formulazione delle query e dal funzionamento del retriever.

Nel dataset B_Adult, i chunk più lunghi di `sliding` non si traducono in prestazioni superiori. Al contrario, questa strategia presenta valori di MAP nettamente inferiori rispetto a `fixed` per tutti i retriever per i quali è disponibile il confronto. Il dato suggerisce che, nel caso analizzato, la maggiore ampiezza dei segmenti non compensi gli eventuali svantaggi associati alla granularità del recupero o alla sovrapposizione delle finestre.

Non è tuttavia possibile attribuire il vantaggio di `fixed` esclusivamente alla lunghezza dei segmenti. Il numero di chunk, la distribuzione delle informazioni, la presenza di tabelle e la composizione del ground truth possono concorrere alle differenze osservate. Per determinare se il risultato dipenda principalmente dalla granularità, dalla sovrapposizione o dalla struttura dei contenuti sarebbero necessari ulteriori esperimenti controllati.

7.3.3 Confronto con la baseline casuale

Per valutare il vantaggio dei sistemi di retrieval rispetto a un ordinamento non informato, il report confronta le MAP osservate con quelle ottenute mediante una baseline casuale. La Tabella 15 riporta le cinque migliori configurazioni e i relativi miglioramenti rispetto al riferimento.

Table 15: Confronto tra le migliori configurazioni RAG e la baseline casuale sul dataset B_Adult.

Configurazione	**MAP reale**	**MAP random**	**Δ MAP**	**Rapporto**
`dense_bge_e5`, fixed	0.5355	0.0466 ± 0.0167	0.4889	11.48×
`single_e5`, fixed	0.5317	0.0466 ± 0.0167	0.4850	11.40×
`dense_bgem3_e5`, fixed	0.5251	0.0466 ± 0.0167	0.4785	11.26×
`single_bgem3`, fixed	0.5217	0.0466 ± 0.0167	0.4750	11.19×
`single_bge`, fixed	0.5197	0.0466 ± 0.0167	0.4731	11.14×

Il confronto mostra che tutte le cinque configurazioni superano ampiamente la baseline casuale. La MAP osservata è compresa tra 0.5197 e 0.5355, mentre il riferimento casuale presenta una media di 0.0466 e una deviazione standard di 0.0167, calcolate su dieci seed. La configurazione `dense_bge_e5` con chunking `fixed` raggiunge una MAP circa 11.48 volte superiore al riferimento, con un incremento assoluto di 0.4889.

Anche `single_e5` e `dense_bgem3_e5` mostrano prestazioni nettamente superiori alla baseline, con rapporti rispettivamente pari a 11.40 e 11.26. Le differenze tra le prime cinque configurazioni sono contenute rispetto al divario tra i sistemi valutati e il riferimento casuale. Questo risultato indica che diverse combinazioni di rappresentazioni dense sono in grado di ottenere ranking competitivi sul dataset B_Adult.

Il vantaggio rispetto alla baseline non riguarda esclusivamente il sistema migliore, ma caratterizza anche le configurazioni basate su un singolo retriever denso. `single_bgem3` e `single_bge` raggiungono infatti rapporti rispettivamente pari a 11.19 e 11.14. Questi valori suggeriscono che l'impiego di rappresentazioni dense sia particolarmente efficace nel recupero delle informazioni pertinenti per le query considerate, anche senza combinare esplicitamente più retriever.

Anche le configurazioni ibride e quelle basate esclusivamente su BM25 superano la baseline casuale, ma con miglioramenti più contenuti. `bm25_e5` con `fixed` raggiunge una MAP di 0.3640,

corrispondente a un rapporto di 7.80 volte il riferimento, mentre `bm25_bge` ottiene 0.3632, pari a 7.79 volte la baseline. La configurazione `single_bm25` raggiunge invece una MAP di 0.2570, corrispondente a un rapporto di 5.51 volte il riferimento casuale.

Le differenze risultano ancora più marcate per la strategia `sliding`. La configurazione `single_bge` raggiunge una MAP di 0.1166, pari a circa 2.24 volte la baseline casuale corrispondente. Per `dense_bge_e5`, la MAP è pari a 0.1017, circa 1.95 volte il riferimento. Il sistema `bm25_e5` raggiunge invece una MAP di 0.0694, pari a circa 1.33 volte la baseline. Sebbene tutti questi risultati siano superiori ai rispettivi riferimenti in termini numerici, il margine è nettamente inferiore rispetto a quello osservato con `fixed`.

È importante considerare che le baseline casuali non sono identiche per tutte le strategie di chunking. Il report riporta una MAP media di 0.0466 per `fixed`, 0.0489 per `hybrid` e 0.0521 per `sliding`. Il confronto tra configurazioni deve quindi utilizzare il riferimento associato alla strategia corrispondente.

Nel complesso, i risultati suggeriscono che la qualità del ranking dipenda in misura rilevante dall'interazione tra retriever e strategia di segmentazione. La baseline casuale costituisce un riferimento utile per quantificare il miglioramento ottenuto dai sistemi, ma non sostituisce un test statistico di significatività. In particolare, il fatto che una configurazione raggiunga una MAP numericamente superiore di un'altra non implica automaticamente che la differenza sia statisticamente significativa.

7.3.4 Analisi delle query

Le metriche aggregate non descrivono completamente il comportamento del sistema sulle singole query. Per questo motivo, il report individua le domande per le quali la configurazione migliore, `dense_bge_e5` con chunking `fixed`, presenta i valori di Average Precision più bassi.

Table 16: Query più difficili per la configurazione `dense_bge_e5` con chunking `fixed` sul dataset B_Adult.

ID	Informazione richiesta	AP	N. rilevanti
D2.2	Geographical area of data collection	0.000	1
D3.4	Data labeling and annotation	0.000	1
D5.5	Label provenance	0.000	1
D5.3	Joint distribution of protected and target	0.077	1
D5.2	Marginal distribution of protected attributes	0.125	4
D1.2	People and organizations involved in the data collection process	0.165	3
D4.1	Available features (or covariates) and their explanation	0.184	6
D1.1	Purpose for original data collection	0.333	1

Le query D2.2, D3.4 e D5.5 presentano un'Average Precision pari a zero. La prima riguarda l'area geografica in cui sono stati raccolti i dati, la seconda il processo di etichettatura e annotazione, mentre la terza richiede informazioni sulla provenienza delle etichette. In tutti e tre i casi, il ground truth comprende un solo elemento rilevante. Il sistema non riesce quindi a collocare tale elemento in una posizione utile ai fini della metrica AP.

Questi risultati mostrano che alcune informazioni specifiche rimangono difficili da recuperare anche per la configurazione con la MAP complessiva più elevata. In particolare, le domande sulla provenienza delle informazioni e sulle procedure di annotazione possono richiedere l'individuazione di passaggi circoscritti del documento, nei quali il contenuto rilevante potrebbe non essere espresso utilizzando la stessa terminologia della query.

La query D5.3, relativa alla distribuzione congiunta degli attributi protetti e della variabile target, raggiunge una AP pari a 0.077, con un solo elemento rilevante nel ground truth. Anche

D5.2, relativa alla distribuzione marginale degli attributi protetti, presenta un risultato limitato, con AP pari a 0.125 nonostante la presenza di quattro elementi rilevanti. Le prestazioni suggeriscono che le informazioni relative alla distribuzione statistica degli attributi e alle loro relazioni possano richiedere un recupero più articolato rispetto a quello necessario per contenuti descrittivi generali.

La query D1.2, relativa alle persone e alle organizzazioni coinvolte nel processo di raccolta dei dati, raggiunge una AP di 0.165, con tre elementi rilevanti. Anche la query D4.1, relativa alle caratteristiche o covariate disponibili e alle rispettive descrizioni, presenta una AP contenuta, pari a 0.184, nonostante il ground truth comprenda sei elementi rilevanti. Quest'ultimo caso è particolarmente significativo, poiché la presenza di numerosi elementi rilevanti non garantisce che il sistema riesca a recuperarli e ordinarli in modo efficace.

La query D1.1, relativa allo scopo originario della raccolta dei dati, presenta invece il valore di AP più elevato tra le query riportate, pari a 0.333. Il risultato rimane comunque inferiore alla MAP complessiva della configurazione, pari a 0.5355. È opportuno ricordare che l'AP di una singola query e la MAP aggregata misurano aspetti differenti: la prima descrive la qualità del ranking per una specifica domanda, mentre la seconda rappresenta la media delle AP su tutte le query valutate.

L'analisi delle query evidenzia inoltre che le difficoltà non sono distribuite uniformemente tra le diverse aree tematiche. Le domande appartenenti al gruppo D5, relative agli attributi protetti, alle distribuzioni statistiche e alla provenienza delle etichette, mostrano risultati particolarmente limitati. Anche alcune richieste descrittive e metodologiche, come l'area geografica della raccolta e il processo di annotazione, risultano problematiche.

Questi risultati suggeriscono che le prestazioni aggregate del sistema non siano sufficienti a garantire un recupero uniforme di tutte le tipologie di informazione. Una possibile linea di miglioramento consiste nel combinare il retrieval denso con tecniche di decomposizione delle query e reranking, soprattutto per le domande che richiedono informazioni specifiche o distribuite in più punti del documento.

Ad esempio, la domanda relativa alle caratteristiche disponibili potrebbe essere scomposta in richieste distinte per identificare i nomi delle variabili, le rispettive descrizioni e le eventuali relazioni con gli attributi protetti. Analogamente, la domanda sulla provenienza delle etichette potrebbe essere formulata attraverso sotto-domande dedicate alla fonte delle annotazioni, alle procedure di assegnazione delle etichette e agli eventuali interventi umani.

Tali interventi dovrebbero essere valutati sperimentalmente, verificando se producano miglioramenti sulle query più difficili senza compromettere le prestazioni complessive del sistema. Sarebbe inoltre utile confrontare i risultati prima e dopo il reranking, mantenendo invariati il corpus, il ground truth e le altre componenti della pipeline.

7.3.5 Conclusioni B_Adult

La configurazione `dense_bge_e5` con chunking `fixed` rappresenta la soluzione migliore in termini di MAP, con un valore pari a 0.5355 e un incremento assoluto di 0.4889 rispetto alla baseline casuale. La prestazione è circa 11.48 volte superiore al riferimento, evidenziando l'efficacia della combinazione tra le rappresentazioni dense BGE ed E5 per le query considerate.

Le configurazioni `single_e5` e `dense_bgem3_e5`, anch'esse basate su `fixed`, ottengono MAP rispettivamente pari a 0.5317 e 0.5251. La ridotta differenza rispetto al primo classificato indica che più configurazioni dense possono raggiungere prestazioni competitive. In particolare, il risultato di `single_e5` suggerisce che l'impiego di un singolo retriever possa avvicinarsi alle prestazioni di una combinazione di modelli, almeno nelle condizioni sperimentali considerate.

La configurazione `single_bge` presenta invece l'Hit@20 più elevato tra le prime cinque, pari al 90.5%, con soltanto due query aventi AP nulla. Questo risultato evidenzia una differenza tra la massimizzazione della qualità media del ranking e la copertura delle singole query. Quando l'obiettivo prioritario è massimizzare la MAP, `dense_bge_e5` costituisce la scelta migliore; quando

si privilegia la probabilità di recuperare almeno un documento rilevante per ciascuna domanda, `single_bge` rappresenta un'alternativa interessante.

La strategia `fixed` risulta la più efficace per tutti i retriever per i quali sono disponibili confronti tra le diverse strategie di chunking, mentre `sliding` presenta le prestazioni inferiori. La strategia `hybrid` occupa una posizione intermedia, mantenendo risultati relativamente competitivi per i sistemi densi, ma senza raggiungere i valori ottenuti con `fixed`. L'andamento è coerente con quanto osservato sul dataset D_German e suggerisce che, nei due dataset analizzati, la segmentazione a lunghezza fissa sia particolarmente adatta alle query valutate.

Le statistiche sui chunk mostrano che `fixed` produce 63 segmenti con una lunghezza media di 481.3 caratteri, mentre `sliding` genera 57 segmenti con una lunghezza media di 657.5 caratteri. La maggiore lunghezza dei segmenti `sliding` non determina un miglioramento del retrieval. Una possibile interpretazione è che una segmentazione più uniforme favorisca la localizzazione delle informazioni rilevanti, mentre finestre più ampie e sovrapposte possano introdurre ridondanza o ridurre la precisione con cui vengono individuati passaggi specifici. Tale interpretazione richiede tuttavia ulteriori verifiche sperimentali.

Il confronto con la baseline casuale conferma il vantaggio delle configurazioni valutate. Tutte le cinque migliori configurazioni raggiungono una MAP superiore a 0.51, a fronte di una media casuale pari a 0.0466. Anche i sistemi basati su BM25 superano il riferimento, pur mostrando risultati inferiori rispetto alle configurazioni dense. La differenza suggerisce che, per il dataset B_Adult, le rappresentazioni dense risultino particolarmente efficaci nell'identificazione dei contenuti pertinenti. Non è tuttavia possibile attribuire tale vantaggio esclusivamente alla natura semantica del retrieval senza ulteriori esperimenti controllati.

L'analisi delle singole query evidenzia che alcune informazioni rimangono difficili da recuperare anche con la configurazione migliore. In particolare, le domande relative all'area geografica della raccolta, al processo di annotazione e alla provenienza delle etichette presentano AP nulla. Anche le query riguardanti la distribuzione degli attributi protetti e le caratteristiche disponibili mostrano prestazioni limitate. Questi risultati indicano che il sistema può raggiungere una MAP complessiva elevata pur mantenendo difficoltà su specifiche categorie di informazioni.

In conclusione, per il dataset B_Adult i risultati suggeriscono di preferire `dense_bge_e5` con chunking `fixed` quando l'obiettivo prioritario è massimizzare la qualità complessiva del ranking. Se invece è fondamentale aumentare la probabilità di recuperare almeno un documento pertinente per ogni query, `single_bge` con la medesima strategia di segmentazione costituisce un'alternativa interessante. Queste conclusioni restano circoscritte alle configurazioni, alle query e ai ground truth utilizzati nell'esperimento e dovrebbero essere confermate mediante ulteriori valutazioni prima di essere generalizzate ad altri dataset.

7.4 EHSRQL

La Tabella riporta le cinque migliori configurazioni RAG in termini di Mean Average Precision (MAP) sul dataset EHSRQL, considerando il gruppo sperimentale con ground truth granulare. I risultati mostrano una prevalenza delle configurazioni basate su retrieval denso e della strategia di chunking `fixed`. La configurazione `single_bge` raggiunge la MAP più elevata, pari a 0.3989, seguita da `dense_bge_e5`, con 0.3890, e `single_e5`, con 0.3873.

Le prime tre configurazioni utilizzano tutte la strategia `fixed` e ottengono valori di MAP molto vicini, compresi tra 0.3873 e 0.3989. Il risultato evidenzia la competitività delle rappresentazioni dense sul dataset considerato e suggerisce che una segmentazione a lunghezza fissa costituisca una scelta favorevole per i sistemi con le prestazioni più elevate. La configurazione `dense_bge_e5` presenta inoltre un Hit@20 dell'88.9%, equivalente a quello di `single_e5`, con tre sole query caratterizzate da Average Precision nulla.

Table 17: Le cinque migliori configurazioni RAG per MAP sul dataset EHSRQL con ground truth granulare.

Configurazione	MAP	Hit@20 (%)	Query con AP nulla	Rapporto random
`single_bge`	0.3989	81.5	5/27	17.85×
`dense_bge_e5`	0.3890	88.9	3/27	17.41×
`single_e5`	0.3873	88.9	3/27	17.34×
`dense_bge_e5` (sliding)	0.3419	81.5	5/27	13.01×
`bm25_e5`	0.3136	74.1	7/27	14.04×

La configurazione `single_bge` con chunking `fixed` raggiunge una MAP pari a 0.3989, risultando la migliore tra le configurazioni valutate nel gruppo con ground truth granulare. Rispetto alla baseline casuale, la cui MAP media è pari a 0.0223 ± 0.0081, il miglioramento assoluto riportato è di 0.3765, corrispondente a un risultato circa 17.85 volte superiore al riferimento. Il dato evidenzia una capacità di ordinamento dei documenti nettamente superiore a quella ottenibile mediante un ranking casuale.

Le prestazioni della configurazione migliore sono seguite da quelle di `dense_bge_e5`, che raggiunge una MAP di 0.3890, e di `single_e5`, con 0.3873. Lo scarto tra la prima e la seconda configurazione è pari a 0.0099, mentre la differenza tra la prima e la terza è pari a 0.0116. Le differenze risultano quindi relativamente contenute: in particolare, la configurazione basata sul singolo retriever BGE supera le altre due, ma non con un margine tale da consentire, in assenza di test statistici, di concludere che le prestazioni siano significativamente differenti.

Un elemento rilevante riguarda il confronto tra configurazioni dense combinate e retriever singoli. La configurazione `single_bge` ottiene la MAP più elevata, mentre `dense_bge_e5`, che combina BGE ed E5 mediante Reciprocal Rank Fusion (RRF), raggiunge un risultato di poco inferiore. Anche `single_e5` presenta una MAP molto vicina a quella della configurazione migliore. Questi valori suggeriscono che, sul dataset EHSRQL, un singolo retriever denso possa raggiungere prestazioni competitive rispetto a una combinazione di più sistemi di retrieval.

La configurazione `single_bge` presenta tuttavia un Hit@20 dell'81.5%, inferiore all'88.9% ottenuto sia da `dense_bge_e5` sia da `single_e5`. Il sistema recupera almeno un documento rilevante per 22 delle 27 query valutate, mentre le altre due configurazioni raggiungono tale obiettivo per 24 query. Di conseguenza, il sistema con la MAP più elevata non coincide con quello che offre la maggiore copertura delle query.

La differenza evidenzia che la configurazione ottimale dipende anche dall'obiettivo applicativo. Se si intende massimizzare la qualità media del ranking, `single_bge` costituisce la scelta migliore. Se invece si privilegia la copertura delle query e si vuole ridurre il numero di domande per le quali il sistema non recupera documenti pertinenti, `dense_bge_e5` e `single_e5` rappresentano alternative interessanti.

7.4.1 Effetto della strategia di chunking

La Tabella 18 confronta i valori di MAP ottenuti dai retriever con le diverse strategie di segmentazione sul dataset EHSRQL. Per la maggior parte dei sistemi, `fixed` produce i risultati migliori, seguito da `sliding`, mentre `hybrid` presenta le prestazioni più basse. Un'eccezione è rappresentata da `single_bm25`, per il quale `sliding` raggiunge una MAP superiore a quella ottenuta con `fixed`.

Table 18: Confronto della MAP tra retriever e strategie di chunking sul dataset EHSRQL con ground truth granulare.

Retriever	Fixed	Sliding	Hybrid	Media
bm25_bge	0.3014	0.2798	0.1232	0.2348
bm25_e5	0.3136	0.2908	0.0890	0.2311
dense_bge_e5	0.3890	0.3419	0.1075	0.2795
single_bge	0.3989	0.2886	0.1128	0.2668
single_bm25	0.1862	0.2143	0.0836	0.1614
single_e5	0.3873	0.2746	0.0940	0.2520

L'analisi evidenzia un vantaggio consistente della strategia `fixed` per cinque dei sei retriever considerati. La configurazione `dense_bge_e5` raggiunge una MAP di 0.3890 con `fixed`, rispetto a 0.3419 con `sliding` e 0.1075 con `hybrid`. Il passaggio da `fixed` a `sliding` determina una riduzione assoluta della MAP pari a 0.0471, mentre la differenza rispetto a `hybrid` è pari a 0.2815.

Un andamento analogo si osserva per `single_bge`, che passa da una MAP di 0.3989 con `fixed` a 0.2886 con `sliding` e 0.1128 con `hybrid`. In questo caso, la differenza tra `fixed` e `sliding` è pari a 0.1103, mentre quella tra `fixed` e `hybrid` raggiunge 0.2861. Anche `single_e5` mostra differenze marcate, con valori rispettivamente pari a 0.3873, 0.2746 e 0.0940. Per questo sistema, il vantaggio di `fixed` rispetto a `sliding` è pari a 0.1127.

Le configurazioni ibride che combinano BM25 con rappresentazioni dense mostrano valori inferiori rispetto ai sistemi densi nelle configurazioni migliori. `bm25_e5` raggiunge una MAP di 0.3136 con `fixed`, 0.2908 con `sliding` e 0.0890 con `hybrid`. Per `bm25_bge`, i valori sono rispettivamente pari a 0.3014, 0.2798 e 0.1232. Anche in questo caso, la strategia `hybrid` determina una riduzione significativa della MAP rispetto alle altre due modalità di segmentazione.

L'andamento di `single_bm25` costituisce un'eccezione. Questo sistema raggiunge una MAP di 0.2143 con `sliding`, superiore al valore di 0.1862 ottenuto con `fixed`. La differenza è pari a 0.0281. Entrambi i risultati rimangono tuttavia inferiori a quelli delle configurazioni dense e ibride che combinano BM25 con BGE o E5. L'eccezione suggerisce che l'effetto della segmentazione non sia indipendente dal retriever utilizzato e che la strategia ottimale possa variare in funzione delle caratteristiche del sistema di recupero.

La strategia `hybrid` presenta sistematicamente le MAP più basse per tutti i retriever considerati. I risultati sono particolarmente evidenti per `dense_bge_e5`, per il quale la MAP scende da 0.3890 con `fixed` a 0.1075 con `hybrid`, e per `single_e5`, che passa da 0.3873 a 0.0940. Questo andamento indica che, nelle condizioni sperimentali considerate, il chunking `hybrid` non risulta favorevole alla qualità del ranking.

La media descrittiva più elevata tra i retriever è quella di `dense_bge_e5`, pari a 0.2795, seguita da `single_e5`, con 0.2520, e `bm25_bge`, con 0.2348. Tali medie riassumono le prestazioni dei sistemi sulle tre strategie di segmentazione, ma non devono essere interpretate come misure indipendenti dalle caratteristiche dei corpus. Le strategie di chunking possono infatti produrre insiemi di segmenti differenti e influenzare la corrispondenza tra gli elementi recuperati e il ground truth.

Nel complesso, i risultati suggeriscono che, per il dataset EHSRQL, la segmentazione a lunghezza fissa rappresenti la scelta preferibile per la maggior parte dei retriever. La strategia `sliding` costituisce un'alternativa competitiva per alcuni sistemi, in particolare per quelli

basati su BM25, mentre `hybrid` presenta risultati sensibilmente inferiori. Queste osservazioni descrivono l'andamento delle configurazioni valutate, ma non dimostrano che la strategia di chunking sia l'unica causa delle differenze: per isolare il suo effetto sarebbe necessario mantenere costanti le altre componenti della pipeline e verificare la comparabilità dei ground truth.

7.4.2 Caratteristiche dei chunk

Le statistiche relative ai chunk permettono di contestualizzare i risultati del retrieval e di approfondire le differenze tra le strategie di segmentazione utilizzate sul dataset EHSRQL.

Table 19: Statistiche descrittive dei chunk per strategia di segmentazione sul dataset EHSRQL.

Strategia	N. chunk	Media caratteri	Mediana	Massimo	Con tabelle (%)
`fixed`	171	501.0	512.0	2291	1.2
`hybrid`	171	503.3	512.0	2493	1.2
`sliding`	143	776.0	616.0	4918	1.4

La strategia `fixed` produce 171 chunk, lo stesso numero ottenuto con `hybrid`, mentre `sliding` genera 143 segmenti. I chunk `fixed` presentano una lunghezza media di 501.0 caratteri e una mediana di 512 caratteri. Per `hybrid`, la media sale leggermente a 503.3 caratteri, mentre la mediana rimane pari a 512 caratteri. La strategia `sliding` genera invece segmenti mediamente più lunghi, con una media di 776.0 caratteri e una mediana di 616 caratteri.

La lunghezza massima è pari a 2291 caratteri per `fixed`, 2493 per `hybrid` e 4918 per `sliding`. Anche la percentuale di chunk contenenti tabelle è leggermente superiore per `sliding`, pari all'1.4%, rispetto all'1.2% delle altre due strategie.

Le statistiche mostrano che `fixed` e `hybrid` producono lo stesso numero di segmenti e presentano lunghezze medie e mediane molto simili. Differiscono tuttavia per la lunghezza massima dei segmenti, che risulta maggiore per `hybrid`. La strategia `sliding`, invece, genera meno chunk, caratterizzati da una lunghezza media e massima sensibilmente superiori. Queste differenze indicano che le strategie non producono soltanto suddivisioni differenti, ma anche unità testuali con caratteristiche dimensionali diverse.

La lunghezza dei segmenti può influire sul retrieval, poiché determina il livello di granularità con cui le informazioni vengono indicizzate e recuperate. Chunk più brevi possono favorire la localizzazione di passaggi specifici, mentre segmenti più lunghi possono preservare una quantità maggiore di contesto. L'effetto concreto dipende tuttavia dal contenuto dei documenti, dalla formulazione delle query e dal funzionamento del retriever.

Nel dataset EHSRQL, i segmenti mediamente più lunghi di `sliding` non determinano prestazioni superiori rispetto a `fixed` per la maggior parte dei retriever. Al contrario, `dense_bge_e5`, `single_bge`, `single_e5`, `bm25_e5` e `bm25_bge` raggiungono tutti una MAP maggiore con `fixed`. La configurazione `single_bm25` costituisce invece un'eccezione, poiché ottiene una MAP superiore con `sliding`.

Questi risultati suggeriscono che la maggiore ampiezza dei segmenti non sia sufficiente, da sola, a migliorare il ranking. Una possibile interpretazione è che, per le rappresentazioni dense, una segmentazione più uniforme favorisca l'associazione tra le informazioni richieste e i contenuti recuperati. Le finestre più ampie di `sliding` potrebbero invece introdurre contenuti aggiuntivi che rendono meno specifica la corrispondenza tra query e segmento. Si tratta tuttavia di ipotesi interpretative, non di conclusioni causali.

Anche la strategia `hybrid`, pur producendo segmenti con lunghezze medie simili a quelle di `fixed`, presenta prestazioni nettamente inferiori. Questo dato suggerisce che la sola lunghezza dei chunk non sia sufficiente a spiegare le differenze osservate. Potrebbero essere rilevanti anche

il posizionamento dei confini, la distribuzione delle informazioni tra segmenti, la struttura dei documenti e il numero di elementi effettivamente recuperabili.

La percentuale di chunk contenenti tabelle risulta inoltre relativamente contenuta per tutte le strategie. Il dato, da solo, non permette di stabilire se il contenuto tabellare influenzi le prestazioni, poiché non descrive la rilevanza delle tabelle per le singole query né la qualità con cui le informazioni tabellari sono state estratte dal PDF.

Per determinare se il vantaggio di `fixed` dipenda principalmente dalla granularità, dalla struttura dei segmenti o dalla distribuzione delle informazioni sarebbe necessario condurre ulteriori esperimenti controllati. In particolare, sarebbe utile confrontare strategie con lunghezza media e numero di chunk comparabili, mantenendo invariati il retriever, il corpus di riferimento e il ground truth.

7.4.3 Confronto con la baseline casuale

Per valutare il vantaggio dei sistemi di retrieval rispetto a un ordinamento non informato, il report confronta le MAP osservate con quelle ottenute mediante una baseline casuale. La Tabella 20 riporta le cinque migliori configurazioni e i relativi miglioramenti rispetto al riferimento.

Table 20: Confronto tra le migliori configurazioni RAG e la baseline casuale sul dataset EHSRQL.

Configurazione	MAP reale	MAP random	Δ MAP	Rapporto
`single_bge`, fixed	0.3989	0.0223 ± 0.0081	$+0.3765$	$17.85\times$
`dense_bge_e5`, fixed	0.3890	0.0223 ± 0.0081	$+0.3666$	$17.41\times$
`single_e5`, fixed	0.3873	0.0223 ± 0.0081	$+0.3650$	$17.34\times$
`dense_bge_e5`, sliding	0.3419	0.0263 ± 0.0118	$+0.3157$	$13.01\times$
`bm25_e5`, fixed	0.3136	0.0223 ± 0.0081	$+0.2912$	$14.04\times$

Il confronto mostra che tutte le cinque configurazioni superano ampiamente la baseline casuale. La MAP osservata è compresa tra 0.3136 e 0.3989, mentre il riferimento casuale per la strategia `fixed` presenta una media di 0.0223 e una deviazione standard di 0.0081, calcolate su dieci seed. La configurazione `single_bge` con chunking `fixed` raggiunge una MAP circa 17.85 volte superiore al riferimento, con un incremento assoluto riportato di 0.3765.

Anche `dense_bge_e5` e `single_e5` mostrano prestazioni nettamente superiori alla baseline, con rapporti rispettivamente pari a 17.41 e 17.34. Le differenze tra le prime tre configurazioni sono contenute rispetto al divario tra i sistemi valutati e il riferimento casuale. Questo risultato indica che diverse configurazioni basate su rappresentazioni dense sono in grado di ottenere ranking competitivi sul dataset EHSRQL.

Il vantaggio rispetto alla baseline non riguarda esclusivamente i sistemi densi. Anche le configurazioni ibride che combinano BM25 con BGE o E5 superano il riferimento casuale. `bm25_e5` con `fixed` raggiunge una MAP di 0.3136, corrispondente a un rapporto di 14.04 volte il riferimento, mentre `bm25_bge` ottiene 0.3014, pari a 13.49 volte la baseline. La configurazione `single_bm25` raggiunge invece una MAP di 0.1862 con `fixed`, corrispondente a un rapporto di 8.34 volte il riferimento casuale.

Le differenze risultano più contenute per la strategia `hybrid`. La configurazione `bm25_bge` raggiunge una MAP di 0.1232, pari a circa 4.34 volte la baseline casuale corrispondente, mentre `dense_bge_e5` ottiene 0.1075, pari a circa 3.79 volte il riferimento. Per `single_e5`, la MAP è pari a 0.0940, corrispondente a circa 3.31 volte la baseline. Anche in questi casi le prestazioni sono superiori al riferimento, ma il margine risulta nettamente inferiore rispetto a quello osservato con `fixed`.

Per la strategia `sliding`, il rapporto con la baseline varia in funzione del retriever. `dense_bge_e5` raggiunge una MAP di 0.3419, circa 13.01 volte il riferimento casuale, mentre $\texttt{single}_b geottiene 0.2886, pariacirca$

È importante considerare che le baseline casuali non sono identiche per tutte le strategie di chunking. Il report riporta una MAP media di 0.0223 per fixed, 0.0263 per sliding e 0.0284 per hybrid. Il confronto tra configurazioni deve quindi utilizzare il riferimento associato alla strategia corrispondente, evitando di confrontare direttamente i rapporti calcolati rispetto a baseline differenti senza tener conto di questa distinzione.

Nel complesso, i risultati suggeriscono che la qualità del ranking dipenda dall'interazion tra retriever e strategia di segmentazione. La baseline casuale costituisce un riferimento utile per quantificare il miglioramento ottenuto dai sistemi, ma non sostituisce un test statistico di significatività. In particolare, il fatto che una configurazione raggiunga una MAP numericamente superiore a quella di un'altra non implica automaticamente che la differenza sia statisticamente significativa.

7.4.4 Analisi delle query

Le metriche aggregate non descrivono completamente il comportamento del sistema sulle singole query. Per questo motivo, il report individua le domande per le quali la configurazione migliore, single_bge con chunking fixed, presenta i valori di Average Precision più bassi.

Table 21: Query più difficili per la configurazione `single_bge` con chunking `fixed` sul dataset EHSRQL.

ID	Informazione richiesta	AP	N. rilevanti
D4.1	Available features (or covariates) and their explanation	0.000	5
D5.1	Attributes at risk	0.000	3
D5.2	Marginal distribution	0.000	2
D5.3	Joint distribution	0.000	2
D5.6	Bias mitigation	0.000	2
D4.4	Assumptions about representation	0.021	3
D2.2	Geographical area of data collection	0.100	2

Le query D4.1, D5.1, D5.2, D5.3 e D5.6 presentano un'Average Precision pari a zero. La prima riguarda le caratteristiche o covariate disponibili e le rispettive descrizioni; le altre quattro appartengono al gruppo D5 e riguardano gli attributi a rischio, la distribuzione marginale, la distribuzione congiunta e le strategie di mitigazione dei bias. In tutti questi casi, il ground truth comprende almeno due elementi rilevanti, ma il sistema non riesce a recuperarli in posizioni utili ai fini della metrica AP.

La presenza di più elementi rilevanti nel ground truth rende questi risultati particolarme significativi dal punto di vista diagnostico. Per D4.1, ad esempio, sono disponibili cinque elementi rilevanti, ma l'AP è pari a zero. Questo indica che la presenza di un numero relativamente elevato di elementi pertinenti non garantisce che il sistema riesca a individuarli. Il problema potrebbe dipendere dalla formulazione della query, dalla distribuzione delle informazioni nel documento o dalla capacità del retriever di associare la richiesta ai segmenti corretti.

Le query appartenenti al gruppo D5 mostrano difficoltà particolarmente evidenti. D5.1 riguarda gli attributi a rischio, D5.2 la distribuzione marginale, D5.3 la distribuzione congiunta e D5.6 le strategie di mitigazione dei bias. Queste domande affrontano aspetti differenti, ma condividono una possibile caratteristica: richiedono l'individuazione di informazioni specifiche relative agli attributi, alle loro distribuzioni o alle procedure adottate per affrontare eventuali distorsioni.

Una possibile interpretazione è che tali informazioni siano espresse nel documento attraverso terminologie specialistiche, formulazioni indirette o passaggi distribuiti in sezioni differenti. Un retriever denso può non associare sempre correttamente queste formulazioni alla domanda, soprattutto quando il contenuto rilevante è descritto mediante espressioni che differiscono da quelle utilizzate nella query. Questa spiegazione rimane tuttavia un'ipotesi e dovrebbe essere verificata attraverso un'analisi diretta dei segmenti rilevanti e di quelli effettivamente recuperati.

Anche la query D4.4, relativa alle assunzioni sulla rappresentazione, presenta un risultato limitato, con AP pari a 0.021 e tre elementi rilevanti. Il valore indica una capacità molto ridotta di collocare gli elementi pertinenti nelle prime posizioni del ranking. Il risultato suggerisce che anche alcune domande di carattere metodologico possano risultare difficili, specialmente quando richiedono di individuare presupposti o scelte progettuali descritti in modo non esplicito.

La query D2.2, relativa all'area geografica in cui sono stati raccolti i dati, raggiunge invece una AP pari a 0.100, con due elementi rilevanti. Il risultato è superiore a quelli delle query con AP nulla, ma rimane contenuto. La difficoltà potrebbe essere associata alla presenza dell'informazione in passaggi descrittivi o metodologici, oppure all'utilizzo di riferimenti geografici che non coincidono direttamente con la formulazione della domanda.

L'analisi delle query deve essere contestualizzata anche rispetto alle prestazioni aggregate della configurazione migliore. Sebbene single_bge raggiunga una MAP complessiva di 0.3989, alcune domande mostrano un comportamento nettamente meno efficace. Il risultato conferma che una MAP relativamente elevata non implica un recupero uniforme di tutte le categorie informative richieste.

Le medie per domanda madre forniscono ulteriori indicazioni sulle aree in cui il sistema incontra maggiori difficoltà. Per la configurazione single_bge con fixed, il valore medio di MAP per D1 è pari a 0.675, mentre per D3 è pari a 0.481 e per D4 a 0.505. La domanda madre D5 presenta invece una MAP media di appena 0.056, evidenziando un divario particolarmente marcato rispetto agli altri gruppi.

Il confronto tra configurazioni suggerisce inoltre che le difficoltà del gruppo D5 non dipendano esclusivamente dalla strategia di chunking. Per la configurazione dense_bge_e5 con fixed, la MAP media di D5 sale a 0.109, mentre per single_e5 raggiunge 0.128. Con dense_bge_e5 e sliding, il valore arriva a 0.220. Questi risultati indicano che la scelta del retriever e della strategia di segmentazione può modificare sensibilmente le prestazioni sulle singole categorie di domande, anche quando il ranking complessivo risulta migliore con una configurazione differente.

In particolare, il risultato di D5 con dense_bge_e5 e sliding suggerisce che la strategia ottimale possa variare a seconda della tipologia di informazione richiesta. Sebbene questa configurazione raggiunga una MAP complessiva inferiore a quella ottenuta con fixed, può risultare relativamente più efficace per alcune domande. È quindi opportuno evitare di considerare la configurazione con la MAP più elevata come necessariamente migliore per ogni categoria di query.

Una possibile linea di miglioramento consiste nel combinare il retrieval denso con tecniche di decomposizione delle query e reranking, soprattutto per le domande che richiedono informazioni specifiche o distribuite in più punti del documento. Ad esempio, la domanda relativa alle caratteristiche disponibili potrebbe essere scomposta in richieste distinte per identificare i nomi delle variabili, le rispettive descrizioni e le eventuali relazioni con gli attributi a rischio.

Analogamente, le domande relative alle distribuzioni marginali e congiunte potrebbero essere scomposte in sotto-domande dedicate agli attributi considerati, alle distribuzioni riportate e alle relazioni tra gli attributi e la variabile target. Per le richieste

sulla mitigazione dei bias, una decomposizione potrebbe invece distinguere le strategie esplicitamente descritte, le motivazioni della loro adozione e gli eventuali risultati riportati.

Tali interventi dovrebbero essere valutati sperimentalmente, verificando se producano miglioramenti sulle query più difficili senza compromettere le prestazioni complessive del sistema. Sarebbe inoltre utile confrontare i risultati prima e dopo il reranking, mantenendo invariati il corpus, il ground truth e le altre componenti della pipeline.

7.4.5 Conclusioni EHSRQL

Nel complesso, i risultati ottenuti sul dataset EHSRQL mostrano che la qualità del retrieval dipende congiuntamente dalla scelta del retriever e dalla strategia di segmentazione del documento. La configurazione single_bge con chunking fixed rappresenta la soluzione migliore in termini di MAP, con un valore pari a 0.3989 e un incremento assoluto riportato di 0.3765 rispetto alla baseline casuale. La prestazione è circa 17.85 volte superiore al riferimento, evidenziando l'efficacia del retriever denso BGE per le query considerate.

Le configurazioni dense_bge_e5 e single_e5, anch'esse basate su fixed, ottengono MAP rispettivamente pari a 0.3890 e 0.3873. La ridotta differenza rispetto al primo classificato indica che più configurazioni dense possono raggiungere prestazioni competitive. In particolare, il risultato di single_e5 suggerisce che l'impiego di un singolo retriever possa avvicinarsi alle prestazioni di una combinazione di modelli, almeno nelle condizioni sperimentali considerate.

La configurazione dense_bge_e5 presenta invece l'Hit@20 più elevato tra le prime tre, pari all'88.9%, condividendo questo risultato con single_e5. Entrambe le configurazioni presentano tre query con AP nulla, contro le cinque di single$_b$ge.$Questo risultato evidenzia una di f f$

La strategia fixed risulta la più efficace per cinque dei sei retriever considerati, mentre hybrid presenta sistematicamente le prestazioni più basse. La strategia sliding occupa una posizione intermedia per la maggior parte dei sistemi, ma risulta preferibile a fixed per single_bm25. Questo andamento suggerisce che l'effetto della segmentazione dipenda anche dalla natura del retriever utilizzato e che non esista necessariamente una strategia ottimale per tutte le configurazioni.

Le statistiche sui chunk mostrano che fixed produce 171 segmenti con una lunghezza media di 501.0 caratteri, mentre sliding genera 143 segmenti con una lunghezza media di 776.0 caratteri. La maggiore lunghezza dei segmenti sliding non determina un miglioramento generalizzato del retrieval. Una possibile interpretazione è che una segmentazione più uniforme favorisca la localizzazione delle informazioni rilevanti, mentre finestre più ampie possano introdurre contenuti aggiuntivi che riducono la specificità dei segmenti recuperati. Tale interpretazione richiede tuttavia ulteriori verifiche sperimentali

Il confronto con la baseline casuale conferma il vantaggio delle configurazioni valutate. Le prime cinque configurazioni raggiungono una MAP compresa tra 0.3136 e 0.3989, a fronte di una media casuale pari a 0.0223 per fixed. Anche i sistemi basati su BM25 superano il riferimento, pur mostrando risultati inferiori rispetto alle configurazioni dense. La differenza suggerisce che le rappresentazioni dense siano particolarmente efficaci nell'identificazione dei contenuti pertinenti per le query considerate. Non è tuttavia possibile attribuire tale vantaggio esclusivamente alla natura semantica del retrieval senza ulteriori esperimenti controllati.

L'analisi delle singole query evidenzia che alcune informazioni rimangono difficili da recuperare anche con la configurazione migliore. In particolare, le domande relative alle caratteristiche disponibili, agli attributi a rischio, alle distribuzioni marginali e congiunte e alla mitigazione dei bias presentano AP nulla. La MAP media della domanda madre D5, pari a 0.056 per single$_b$geconfixed, $con f ermacheledi f f icoltsiconcentranosoprattuttosuques$

Un possibile sviluppo consiste nell'integrare il retrieval denso con strategie di decomposizione delle query e reranking, valutandone l'efficacia sulle domande problematiche. Potrebbe inoltre essere utile analizzare separatamente le query descrittive, metodologiche e statistiche, così da individuare eventuali differenze nel comportamento dei retriever. Queste estensioni dovrebbero essere valutate mediante esperimenti controllati, confrontando sia le prestazioni sulle singole query sia le metriche aggregate.

In conclusione, per il dataset EHSRQL i risultati suggeriscono di preferire single$_b$*geconch*

7.5 Analisi degli Errori

8 Conclusioni